

# Taller 1. Econometría Avanzada

Profesor: Manuel Fernández - Universidad de los Andes

Daniel Ricardo Amaya Alba - 202023156

Mauricio J. Aragón R. - 201729052

Nota: Para el desarrollo de este taller se usó IA para garantizar el ajuste del formato de las tablas a PDF con la librería kableExtra y model summary pues al reportar los resultados en ocasiones obteníamos un error en el código. Por ejemplo en el punto 4 del tercer ejercicio duramos bastante tiempo intentando entender como solucionar un problema al usar rbind con los outputs obtenidos con la función feols del paquete fixest. Para generar el bucle del punto 7 del ejercicio dos también nos apollamos en la IA, intentando comprender la sintaxis del proceso. En cuanto a notación es muy probable que se identifiquen inconsistencias.

## Table of contents

<b>1</b>	<b>Primer Ejercicio</b>	<b>2</b>
1.1	Punto 1 . . . . .	3
1.2	Punto 2 . . . . .	5
1.3	Punto 3 . . . . .	7
1.4	Punto 4 . . . . .	11
<b>2</b>	<b>Segundo Ejercicio</b>	<b>12</b>
2.1	Punto 1 . . . . .	13
2.2	Punto 2 . . . . .	14
2.3	Punto 3 . . . . .	19
2.4	Punto 4 . . . . .	21
2.5	Punto 5 . . . . .	23
2.6	Punto 6 . . . . .	28
2.7	Punto 7 . . . . .	31
2.8	Punto 8 . . . . .	36
<b>3</b>	<b>Tercer Ejercicio</b>	<b>37</b>
3.1	Punto 1 . . . . .	38

3.2 Punto 2 . . . . .	39
3.3 Punto 3 . . . . .	40
3.4 Punto 4 . . . . .	41
3.5 Punto 5 . . . . .	46
3.6 Punto 6 . . . . .	51
3.7 Punto 7 . . . . .	53

## 1 Primer Ejercicio

Desde la perspectiva del capital humano, estudios como el de Cunha & Heckma (2007) encuentran que las intervenciones durante los primeros años de escolaridad son fundamentales para el desarrollo temprano de habilidades y, con ello, para la trayectoria de aprendizaje posterior de los individuos. Una forma de evaluar el éxito de estas intervenciones es mediante el nivel de habilidades cognitivas que desarrollan los estudiantes, dado que estas capacidades constituyen la base de cualquier aprendizaje futuro.

En este contexto, los gobiernos suelen mostrar interés por los programas de digitalización, ya que prometen acelerar el desarrollo del razonamiento y facilitar la adaptación al mundo moderno. Con base en lo anterior, la pregunta de investigación que guiará este ejercicio, inspirada en Cristia et al. (2012), es: ¿cuál es el efecto de participar en un programa de tecnología educativa sobre el desarrollo de habilidades cognitivas de razonamiento abstracto?

Para responder esta pregunta, usted analizará una política implementada por la Secretaría de Educación de Macondo en conjunto con el colegio Sonrisas, ubicado en una zona rural del país. La iniciativa buscaba transformar el modelo educativo tradicional mediante la entrega de laptops diseñadas específicamente para el aprendizaje autodidacta en entornos con limitaciones severas de infraestructura. El programa se enfocó exclusivamente en estudiantes de tercer grado de primaria, nivel que en este colegio cuenta con dos salones. El programa seleccionaba un salón para convertirlo en Aula Tecnológica.

Los estudiantes asignados al Aula Tecnológica realizaban actividades guiadas tres veces por semana utilizando las laptops. Estas actividades se desarrollaban únicamente durante el horario de clases, las cuales fueron adaptadas para incluir ejercicios lógicos y juegos de asociación visual orientados a fortalecer el razonamiento abstracto. Cada actividad estaba vinculada con el tema correspondiente a la clase del día. Adicionalmente, los estudiantes no podían llevar las laptops a sus hogares. Los estudiantes del otro salón, por su parte, continuaron con sus clases de manera habitual.

Considere una muestra de  $N$  estudiantes observados en un diseño de corte transversal. Defina  $Y_i$  como el puntaje del estudiante  $i$  en un test de habilidades cognitivas de razonamiento abstracto. Este test se aplica anualmente a nivel nacional a estudiantes de tercer grado, está definido por el Ministerio de Educación y sus puntajes oscilan entre 0 y 100. Por otro lado,

$D_i$  es una variable dicotómica que toma el valor de 1 si el estudiante  $i$  fue asignado al Aula Tecnológica y 0 en caso contrario.

Para comenzar, suponga que el mecanismo de asignación al tratamiento es desconocido; es decir, no se conocen los criterios que determinaron la elección de un salón sobre el otro ni la forma en que los estudiantes son asignados a cada salón.

### 1.1 Punto 1

**Describa el problema de estimación utilizando el lenguaje de resultados potenciales**

a) **Teniendo en cuenta el contexto presentado, defina formalmente los resultados potenciales  $Y_i(1)$  y  $Y_i(0)$ . Luego, describa el problema de inferencia causal en este contexto.**

**R/:** En este caso el resultado potencial  $Y_i(1)$  se define como el puntaje que obtendría el estudiante  $i$  dado que fue asignado al aula tecnológica. Por su parte el resultado potencial  $Y_i(0)$  es el resultado que obtendría el estudiante  $i$  dado que no fue asignado al aula tecnológica.

Para recuperar el efecto causal de la participación en las aulas tecnológicas en el puntaje obtenido por el estudiante  $i$ , nos gustaría ver la diferencia en sus resultados potenciales, es decir de sus puntajes dado que participó en el aula y que no participó en el aula:

$$\tau_i = Y_i(1) - Y_i(0)$$

Sin embargo, acá nos encontramos con el problema de la inferencia causal. En nuestra muestra  $N$  para el estudiante  $i$  solo se puede observar uno de los dos caminos, o el estudiante fue asignado ( $D_i = 1$ ) o no fue asignado ( $D_i = 0$ ). Es decir, lo que realmente tenemos en nuestra base de datos es:

$$Y_i = Y_i(1)D_i + (1 - D_i)Y_i(0)$$

De tal manera que el resultado observado  $Y_i$  para el estudiante con  $D_i = 1$  sera su resultado potencial dado que participó  $Y_i(1)$  y para el estudiante con  $D_i = 0$  observaremos su resultado potencial dado que no participó  $Y_i(0)$ . Pero nunca seremos capaces de ver para el mismo estudiante  $i$  su resultado dado que participó  $D_i = 1$  y su contrafactual  $D_i = 0$ .

Es por lo anterior que para trabajar con nuestra muestra utilizaremos no el resultado del individuo  $i$  sino que trabajaremos con el promedio de los resultados potenciales, es decir buscaremos estimar los efectos promedio, bien sea el efecto promedio del tratamiento  $ATE$ , el efecto promedio del tratamiento en los tratados  $ATT$  y el efecto promedio del tratamiento en los no tratados  $ATU$ .

**b) Define en lenguaje matemático el ATE, el ATT y el ATU. Interprete cada uno de estos conceptos de acuerdo al contexto del caso**

**R/:**

El *ATE* se define como el efecto promedio del tratamiento:

$$\begin{aligned}\tau_{ATE} &= E[Y_i(1) - Y_i(0)] \\ \tau_{ATE} &= E[Y_i(1)] - E[Y_i(0)]\end{aligned}$$

Que para el caso de nuestra investigación representa la diferencia entre el puntaje promedio en el test de habilidad cognitivas si toda la población de estudiantes de tercer grado hubieran asistido a las aulas tecnológicas, frente al promedio si ninguno hubiera asisitido a dichas aulas.

El *ATT* se define como el efecto promedio del tratamiento en los tratados:

$$\begin{aligned}\tau_{ATT} &= E[Y_i(1) - Y_i(0)|D_i = 1] \\ \tau_{ATT} &= E[Y_i(1)|D_i = 1] - E[Y_i(0)|D_i = 1]\end{aligned}$$

En este caso representa la diferencia en el puntaje promedio del test de habilidades cognitivas del salón que fue asignado a las aulas tecnológicas y el resultado que esos mismos estudiantes hubieran obtenido si no hubieran sido asignados. Es decir, en este caso estamos restringiendo el efecto promedio al grupo que fue tratado.

El *ATU* se define como el efecto promedio del tratamiento en los no tratados:

$$\begin{aligned}\tau_{ATU} &= E[Y_i(1) - Y_i(0)|D_i = 0] \\ \tau_{ATU} &= E[Y_i(1)|D_i = 0] - E[Y_i(0)|D_i = 0]\end{aligned}$$

En este caso representa la diferencia en el puntaje promedio del test de habilidades cognitivas del salón que no fue asignado a las aulas tecnológicas y el resultado que esos mismos estudiantes hubieran obtenido si hubieran sido asignados. Es decir, en este caso estamos restringiendo el efecto promedio al grupo que no fue tratado.

## 1.2 Punto 2

Usted se encuentra interesada en estimar el siguiente efecto causal:

$$\tau = E[Y_i(1)] - E[Y_i(0)]$$

Para esto plantea una diferencia de medias ingenua

$$\tau_{naive} = E[Y_i|D_i = 1] - E[Y_i|D_i = 0]$$

a). Muestre formalmente que:

$$\tau_{naive} = ATT + E[Y_i(0)|D_i = 1] - E[Y_i(0)|D_i = 0]$$

R/:

$$\begin{aligned}\tau_{naive} &= E[Y_i|D_i = 1] - E[Y_i|D_i = 0] \\ \tau_{naive} &= E[Y_i(1)|D_i = 1] - E[Y_i(0)|D_i = 0] + \cancel{E[Y_i(0)|D_i = 1]} - \cancel{E[Y_i(0)|D_i = 1]} \\ \tau_{naive} &= \underbrace{E[Y_i(1)|D_i = 1] - \cancel{E[Y_i(0)|D_i = 1]}}_{ATT} + \cancel{E[Y_i(0)|D_i = 1]} - E[Y_i(0)|D_i = 0] \\ \tau_{naive} &= ATT + \underbrace{\cancel{E[Y_i(0)|D_i = 1]} - E[Y_i(0)|D_i = 0]}_{\text{Selection Bias}}\end{aligned}$$

b). Muestre formalmente que:

$$\tau_{naive} = ATU + E[Y_i(1)|D_i = 1] - E[Y_i(1)|D_i = 0]$$

R/:

$$\begin{aligned}\tau_{naive} &= E[Y_i|D_i = 1] - E[Y_i|D_i = 0] \\ \tau_{naive} &= E[Y_i(1)|D_i = 1] - E[Y_i(0)|D_i = 0] + \cancel{E[Y_i(1)|D_i = 0]} - \cancel{E[Y_i(1)|D_i = 0]} \\ \tau_{naive} &= \underbrace{E[Y_i(1)|D_i = 0] - \cancel{E[Y_i(0)|D_i = 0]}}_{ATU} + E[Y_i(1)|D_i = 1] - \cancel{E[Y_i(1)|D_i = 0]} \\ \tau_{naive} &= ATU + \underbrace{E[Y_i(1)|D_i = 1] - \cancel{E[Y_i(1)|D_i = 0]}}_{\text{Heterogeneity Bias}}\end{aligned}$$

c). Muestre formalmente que:

$$ATE = \pi ATT + (1 - \pi) ATU$$

**R/:** Esta demostración es diferente a las anteriores, es menos intuitiva. Sin embargo, podemos aplicar la ley de esperanzas iteradas a la definición de *ATE*. Recordemos que la ley de esperanzas iteradas  $E[X] = E[E[X|Y]]$ , de tal forma tenemos:

$$\begin{aligned}\tau_{ATE} &= E[Y_i(1)] - E[Y_i(0)] \\ \tau_{ATE} &= E[E[Y_i(1) - Y_i(0)|D_i]] \\ \tau_{ATE} &= E[Y_i(1) - Y_i(0)|D_i = 1]P(D_i = 1) + E[Y_i(1) - Y_i(0)|D_i = 0]P(D_i = 0)\end{aligned}$$

**Donde:**

$$\tau_{ATE} = \underbrace{E[Y_i(1) - Y_i(0)|D_i = 1]}_{ATT} \cdot \underbrace{P(D_i = 1)}_{\pi} + \underbrace{E[Y_i(1) - Y_i(0)|D_i = 0]}_{ATU} \cdot \underbrace{P(D_i = 0)}_{(1-\pi)}$$

**Interpretando cada expresión:**

a).

$$\tau_{naive} = ATT + \underbrace{E[Y_i(0)|D_i = 1] - E[Y_i(0)|D_i = 0]}_{\text{Selection Bias}}$$

Esta expresión indica que el  $\tau_{naive}$  recupera el efecto causal sobre los tratados (*ATT*) si y solo si el sesgo de selección es igual a cero. Esto ocurre cuando el resultado promedio contrafactual del grupo tratado  $E[Y_i(0)|D_i = 1]$  es idéntico al resultado promedio observado del grupo de control  $E[Y_i(0)|D_i = 0]$ . Para que esto se cumpla la composición de los salones debería ser homogénea o el proceso de asignación debería haber sido aleatorio, garantizando que no existan diferencias pre-existentes entre ambos grupos.

b).

$$\tau_{naive} = ATU + \underbrace{E[Y_i(1)|D_i = 1] - E[Y_i(1)|D_i = 0]}_{\text{Heterogeneity Bias}}$$

Por otro lado esta expresión nos indica que el  $\tau_{naive}$  recupera el efecto promedio causal sobre los no tratados (*ATU*) si y solo si el sesgo de heterogeneidad en resultados del tratamiento es igual a cero. Esto ocurre cuando el resultado promedio de los estudiantes tratados  $E[Y_i(1)|D_i = 1]$  es igual al resultado promedio que hubieran obtenido los estudiantes del grupo de control si se les hubiera asignado el tratamiento  $E[Y_i(1)|D_i = 0]$ . Esto quiere decir que el efecto de las computadoras sería el mismo, independientemente del salón que hubiera sido seleccionado.  
**PREGUNTAR A MANUEL.**

c).

$$ATE = \pi \cdot ATT + (1 - \pi) \cdot ATU$$

Por último esta expresión nos dice que el efecto promedio del tratamiento es un promedio ponderado del efecto promedio en los tratados  $ATT$  y en los no tratados  $ATU$ .

**¿Es cierto que si  $\tau_{naive} = ATT$ , entonces  $\tau_{naive} = ATU$ ?**

Esta afirmación no es cierta. Como vimos, el  $\tau_{naive} = ATT$  sí y solo sí el resultado promedio contrafactual del grupo tratado  $E[Y_i(0)|D_i = 1]$  es idéntico al resultado promedio observado del grupo de control  $E[Y_i(0)|D_i = 0]$ , lo cual no nos está brindando ninguna información al respecto de algún posible sesgo de heterogeneidad del tratamiento, es decir no nos garantiza que el efecto del tratamiento sea el mismo para ambos grupos. Por su parte, si el  $\tau_{naive} = ATU$  solo sabemos que hay ausencia de sesgo de heterogeneidad, pero no tenemos certeza al respecto de la comparabilidad de los grupos (sesgo de selección).

Teniendo como base la descomposición que se hace en libro Causal Inference: The Mixtape Scott Cunningham podemos demostrar la relación entre estos parámetros:

$$\begin{aligned}\tau_{ATE} &= \pi \cdot ATT + (1 - \pi) \cdot ATU \\ \tau_{ATE} &= \pi \cdot ATT + (1 - \pi) \cdot ATU + (1 - \pi) \cdot ATT - (1 - \pi) \cdot ATT \\ \tau_{ATE} &= \cancel{ATT} \cdot \underbrace{(\pi + 1 - \pi)}_1 - (1 - \pi) \cdot ATT + (1 - \pi) \cdot ATU \\ \tau_{ATE} &= ATT - (1 - \pi) \cdot ATT + (1 - \pi) \cdot ATU\end{aligned}$$

Despejando  $ATT$ :

$$\tau_{ATT} = ATE + (1 - \pi) \cdot (ATT - ATU)$$

Remplazando la expresión que acabamos obtener de  $\tau_{ATT}$  en nuestro estimador  $\tau_{naive}$ , obtenemos la descomposición completa del sesgo:

$$\begin{aligned}\tau_{naive} &= ATT + \underbrace{E[Y_i(0)|D_i = 1] - E[Y_i(0)|D_i = 0]}_{\text{Selection Bias}} \\ \tau_{naive} &= ATE + \underbrace{(1 - \pi) \cdot (ATT - ATU)}_{\text{Heterogeneity Bias}} + \underbrace{E[Y_i(0)|D_i = 1] - E[Y_i(0)|D_i = 0]}_{\text{Selection Bias}}\end{aligned}$$

Por lo tanto en nuestro caso, es posible que el salón elegido fuera comparable inicialmente al de control (sin sesgo de selección), pero que las laptops tengan un retorno mayor en el salón tratado debido a factores específicos del grupo o del profesor. Por lo tanto para que  $ATE = ATT = ATU$  necesitamos tener ausencia de heterogeneidad y de selección.

### 1.3 Punto 3

Para encontrar el efecto causal promedio de participar en el programa de tecnología educativa sobre el resultado en el test, considere el siguiente modelo lineal:

$$Y_i = \beta_0 + \tau D_i + U_i$$

**Demuestre que el estimador  $\hat{\tau}_{MCO}$  coincide con la diferencia de medias entre el grupo de tratados y el grupo de no tratados. Es decir, pruebe que  $\hat{\tau}_{MCO} = \hat{\tau}_{DM}$ , donde:**

$$\hat{\tau}_{DM} := \frac{1}{N_1} \sum_{\{i:D_i=1\}} Y_i - \frac{1}{N_0} \sum_{\{i:D_i=0\}} Y_i,$$

y donde  $N_1 = \sum_i D_i$ ;  $N_0 = \sum_i (1 - D_i)$ .

**R/:**

Para demostrar que  $\hat{\tau}_{MCO} = \hat{\tau}_{DM}$ , podemos estimar  $\hat{\tau}_{MCO}$  haciendo la minimización de cuadrados a los residuos de nuestro modelo de regresión:

$$\min_{\hat{\beta}_0, \hat{\tau}} \sum_{i=1}^N (Y_i - \hat{\beta}_0 - \hat{\tau} D_i)^2$$

**FOC respecto de  $\hat{\beta}_0$ :**

$$-2 \sum_{i=1}^N (Y_i - \hat{\beta}_0 - \hat{\tau} D_i) = 0$$

$$\sum_{i=1}^N Y_i - N \hat{\beta}_0 - \hat{\tau} \sum_{i=1}^N D_i = 0$$

$$N \bar{Y} - N \hat{\beta}_0 - \hat{\tau} N_1 = 0$$

Despejando  $\hat{\beta}_0$ :

$$\hat{\beta}_0 = \bar{Y} - \hat{\tau} \frac{N_1}{N}$$

**FOC respecto de  $\hat{\tau}$ :**

$$-2 \sum_{i=1}^N (Y_i - \hat{\beta}_0 - \hat{\tau} D_i) D_i = 0$$

Para que la sumatoria exista  $D_i = 1$ :

$$\sum_{i:D_i=1} (Y_i - \hat{\beta}_0 - \hat{\tau}) = 0$$

$$\sum_{i:D_i=1} Y_i - N_1 \hat{\beta}_0 - N_1 \hat{\tau} = 0$$

Despejando  $\hat{\tau}$ :

$$\hat{\tau} = \frac{1}{N_1} \sum_{i:D_i=1} Y_i - \hat{\beta}_0$$

$$\hat{\tau} = \bar{Y}_1 - \hat{\beta}_0$$

Reemplazamos el  $\beta_0$  que obtuvimos:

$$\hat{\tau} = \bar{Y}_1 - \left( \bar{Y} - \hat{\tau} \frac{N_1}{N} \right)$$

$$\hat{\tau} - \hat{\tau} \frac{N_1}{N} = \bar{Y}_1 - \bar{Y}$$

$$\hat{\tau} \left( 1 - \frac{N_1}{N} \right) = \bar{Y}_1 - \bar{Y}$$

Si  $\frac{N_1}{N}$  es la proporción de tratados,  $1 - \frac{N_1}{N}$  es la proporción de controles:

$$\hat{\tau} \left( \frac{N_0}{N} \right) = \bar{Y}_1 - \bar{Y}$$

El promedio es la suma del promedio de los grupos ponderado:

$$\hat{\tau} \left( \frac{N_0}{N} \right) = \bar{Y}_1 - \left( \bar{Y}_1 \frac{N_1}{N} + \bar{Y}_0 \frac{N_0}{N} \right)$$

$$\hat{\tau} \left( \frac{N_0}{N} \right) = \bar{Y}_1 \left( 1 - \frac{N_1}{N} \right) - \bar{Y}_0 \frac{N_0}{N}$$

$$\hat{\tau} \left( \frac{N_0}{N} \right) = \bar{Y}_1 \left( \frac{N_0}{N} \right) - \bar{Y}_0 \left( \frac{N_0}{N} \right)$$

$$\hat{\tau}_{MCO} = \bar{Y}_1 - \bar{Y}_0$$

$$\hat{\tau}_{MCO} = \frac{1}{N_1} \sum_{\{i:D_i=1\}} Y_i - \frac{1}{N_0} \sum_{\{i:D_i=0\}} Y_i$$

Cómo vemos,  $\hat{\tau}_{MCO} = \hat{\tau}_{DM}$ .

**b).¿que supuesto debe cumplirse para que  $\hat{\tau}_{DM}$  sea un estimador insesgado el efecto causal promedio?**

Para verificar que supuesto se debe cumplir vamos a evaluar la insesgadez tomando la esperanza matematica de nuestro estimador:

$$\begin{aligned} E[\hat{\tau}_{DM}] &= E[\bar{Y}_1 - \bar{Y}_0] \\ E[\hat{\tau}_{DM}] &= E[\bar{Y}_1] - E[\bar{Y}_0] \end{aligned}$$

Si usamos notación de resultados potenciales:

$$E[\hat{\tau}_{DM}] = E[Y_i|D_i = 1] - E[Y_i|D_i = 0]$$

Como en la primera demostración del taller, si sumamos y restamos el contrafactual tenemos que:

$$E[\hat{\tau}_{DM}] = \underbrace{E[Y_i(1)|D_i = 1] - E[Y_i(0)|D_i = 1]}_{ATT} + \underbrace{E[Y_i(0)|D_i = 1] - E[Y_i(0)|D_i = 0]}_{\text{Selección Bias}}$$

Por lo tanto, para que nuestro estimador  $\hat{\tau}_{DM}$  se insesgado necesitamos evitar el sesgo de selección lo cual se logra por medio de la aleatorización garantizando que  $(Y_i(1), Y_i(0)) \perp D_i$

Ahora veamos esto como lo podemos obtener también de la recta de regresión. Recordemos que nuestra linea de regresión es:

$$Y_i = \beta_0 + \tau D_i + U_i$$

Partamos del mismo punto que antes:

$$\begin{aligned} E[\hat{\tau}_{DM}] &= E[\bar{Y}_1 - \bar{Y}_0] \\ E[\hat{\tau}_{DM}] &= E[\bar{Y}_1] - E[\bar{Y}_0] \\ E[\hat{\tau}_{DM}] &= E[Y_i|D_i = 1] - E[Y_i|D_i = 0] \end{aligned}$$

Ahora si tomamos estos valores esperados de nuestra recta obtenemos:

$$\begin{aligned} E[Y_i|D_i = 1] &= \beta_0 + \tau + E[U_i|D_i = 1] \\ E[Y_i|D_i = 0] &= \beta_0 + E[U_i|D_i = 0] \end{aligned}$$

Por lo tanto tenemos:

$$E[\hat{\tau}_{DM}] = \beta_0 + \tau + E[U - i|D_i = 1] - (\beta_0 + E[U_i|D_i = 0])$$

tal que:

$$E[\hat{\tau}_{DM}] = \tau + \underbrace{E[U_i|D_i = 1] - E[U - i|D_i = 0]}_{\text{Selection Bias}}$$

Por lo tanto en términos de la recta de regresión el supuesto de independencia  $(Y_i(1), Y_i(0)) \perp D_i$  se traduce en el supuesto de exogenidad  $E[U_i|D_i] = 0$ . Esto nos señala que, para tener un estimador insesgado, no debemos tener factores no observables correlacionados con el tratamiento que afecten el resultado, haciendo a los grupos diferentes.

#### 1.4 Punto 4

Suponga ahora que la asignación de estudiantes a cada salón se realiza de manera aleatoria. De igual forma, la decisión sobre qué salón recibe el tratamiento también se tomó aleatoriamente. Además, todos los estudiantes pertenecientes al salón asignado al tratamiento efectivamente participaron en el programa. Demuestre que el estimador

$$\hat{\tau}_{DM} \xrightarrow{P} \mathbb{E}[Y_i(1) - Y_i(0)|D_i = 1]$$

Puede suponer que el supuesto de SUTVA se cumple. Posteriormente, defina intuitivamente y explique la importancia de la propiedad de consistencia de un estimador.

R/:

Para demostrar que  $\hat{\tau}_{DM} \xrightarrow{P} \mathbb{E}[Y_i(1) - Y_i(0)|D_i = 1]$  empecemos por:

$$\text{plim}[\hat{\tau}_{DM}] = \text{plim} \left( \left( \frac{1}{N_1} \sum_{i:D_i=1} Y_i \right) - \left( \frac{1}{N_0} \sum_{i:D_i=0} Y_i \right) \right)$$

Como vimos en clase, por mapeo continuo (Slutsky):

$$\text{plim}[\hat{\tau}_{DM}] = \text{plim} \left( \frac{1}{N_1} \sum_{i:D_i=1} Y_i \right) - \text{plim} \left( \frac{1}{N_0} \sum_{i:D_i=0} Y_i \right)$$

Así mismo por WLLN:

$$\text{plim}[\hat{\tau}_{DM}] = E[Y_i|D_i = 1] - E[Y_i|D_i = 0]$$

Si escribimos en resultado potencial:

$$\text{plim}[\hat{\tau}_{DM}] = E[Y_i(1)|D_i = 1] - E[Y_i(0)|D_i = 0]$$

Aplicamos la suma y resta del contrafactual:

$$\text{plim}[\hat{\tau}_{DM}] = \underbrace{E[Y_i(1)|D_i = 1] - E[Y_i(0)|D_i = 1]}_{ATT} + \underbrace{E[Y_i(0)|D_i = 1] - E[Y_i(0)|D_i = 0]}_{\text{Selección Bias}}$$

Cómo sabemos por el enunciado que la asignación a los salones fue aleatoriedad entonces podemos estar tranquilo respecto del sesgo de selección, es decir sabemos que  $((Y_i(1), Y_i(0)) \perp D_i)$ :

$$\text{plim}[\hat{\tau}_{DM}] = \underbrace{E[Y_i(1)|D_i = 1] - E[Y_i(0)|D_i = 1]}_{ATT}$$

Simplificando:

$$\text{plim}[\hat{\tau}_{DM}] = \underbrace{E[Y_i(1) - Y_i(0)|D_i = 1]}_{ATT}$$

que es lo mismo que  $\hat{\tau}_{DM} \xrightarrow{P} \mathbb{E}[Y_i(1) - Y_i(0)|D_i = 1]$

**Entonces respecto a la definición intuitiva y explicación de la propiedad de consistencia, podemos decir que esta permite que el efecto recuperado a nivel muestral sea una aproximación que converge en probabilidad al efecto poblacional, lo que permite estar seguros de que nos estamos aproximando al efecto real.**

## 2 Segundo Ejercicio

Tal como señalan [Abadie et al. \(2022\)](#), los errores estándar clusterizados han adquirido un rol central en el trabajo empírico y esto no es casualidad. Si bien una parte sustancial de los esfuerzos de los investigadores se concentra en la obtención de estimadores consistentes e insesgados, resulta también fundamental poder realizar inferencia estadística válida sobre dichos estimadores. En este contexto, una de las prácticas más extendidas en la literatura empírica es el reporte de errores estándar clusterizados. No obstante, su uso plantea varias preguntas recurrentes en la práctica: ¿en qué situaciones es apropiado utilizar este tipo de errores estándar?, ¿cuándo tienen un impacto importante sobre la inferencia estadística? y ¿a qué nivel debería realizarse la clusterización?

Teniendo en cuenta lo anterior, suponga que usted desea estudiar **el impacto de que un estudiante de raza negra tenga un profesor de la misma raza**. Es bien sabido que existen brechas raciales en los resultados educacionales, lo cual resulta problemático por diversas razones: la movilidad social, los ingresos futuros y el bienestar social están estrechamente vinculados al nivel educativo. En este contexto, usted decide seguir la línea de investigación propuesta por [Gershenson et al. \(2022\)](#) y busca replicar algunos de sus principales resultados, en particular aquellos relacionados con el desempeño en exámenes y la entrada a la universidad.

Para realizar estos ejercicios, usted dispone de una base de datos de corte transversal denominada `race_teaching.dta` que proviene de un experimento realizado en EE.UU. que aleatorizaba la raza de los profesores en diferentes salones de kínder. Sus datos están a nivel individual, donde cada observación es una persona de raza negra que participó en el experimento.

Esta base contiene información sobre los resultados en el SAT (examen estandarizado para el ingreso a la universidad) y una variable indicadora que señala si el estudiante asistió a la universidad. A estas variables de interés se las denota por  $Y_i$ . Adicionalmente, la base incluye una variable indicadora  $D_i$ , que toma el valor de uno si el estudiante  $i$  tuvo un profesor de raza negra en kínder y cero en caso contrario. Asimismo, se incorporan características geográficas, tales como el salón, el colegio, el condado y el estado al que pertenece cada individuo.

Antes de abordar las decisiones empíricas que deberá tomar en su investigación, usted decide analizar primero, desde una perspectiva teórica, los errores estándar clusterizados. De este modo, podrá comprender su formulación, sus principales propiedades y sentar las bases para determinar en qué contextos resulta apropiado utilizarlos y cómo deben implementarse.

## 2.1 Punto 1

**Realice un análisis crítico de los supuestos de homocedasticidad y no-correlación del término de error. Para ello:**

- Defina ambos supuestos, tanto desde un punto de vista matemático como intuitivo, en el contexto del caso de estudio.
- Discuta si resulta razonable asumir el cumplimiento de estos supuestos dada la pregunta de investigación. Justifique su respuesta utilizando un ejemplo intuitivo para cada supuesto.

R/:

El supuesto de homocedasticidad implica que  $E[e_i^2|X] = \sigma^2$  que también podría ser visto como  $E[e_i^2|D_i = 1] = \sigma^2$  y  $E[e_i^2|D_i = 0] = \sigma^2$ , lo que quiere decir que la varianza de los errores es constante para cada estudiante, independientemente de sus características ( $X$ ). En este caso, quiere decir que la dispersión en los resultados de la prueba SAT para cada estudiante es la misma para el grupo de estudiantes tratados y no tratados.

Por otro lado, el supuesto de no-correlación implica que  $E[e_i e_j] = 0$ . Esto quiere decir que conocer el error del estudiante  $i$  no me dice nada al respecto del resultado del estudiante  $j$ . Es decir, si a un estudiante le va muy bien en la prueba, por algún factor diferente al tratamiento, eso no quiere decir que a otro estudiante le vaya a ir igual de bien. Es decir, si un estudiante el día del examen se despertó con dolor de cabeza, eso no nos dice nada respecto de otros estudiantes.

El supuesto de homocedasticidad resulta poco plausible en este escenario. Tal como lo señalan Angrist y Pischke (2009) en la vida real, aunque no conocemos la *CEF*, es viable pensar que esta no es lineal necesariamente, por lo que el hecho que no sea lineal ya va a generar por sí mismo que tengamos variabilidad en la forma en que la línea de regresión se aproxima a la *CEF*. Así mismo, hay que tener en cuenta que una de nuestras variables dependientes es binaria (asistencia a la universidad), de acuerdo con los autores mencionados, esto anula el supuesto de homocedasticidad porque por simple construcción va a haber variación en los errores.

Por otro lado, Abadie et al.(2023) señalan que el ajuste por cluster de errores estándar se debe hacer por nivel de muestreo y de asignación de tratamiento. En este caso el tratamiento fue asignado por salones, por lo que no solo no deberíamos asumir errores homocedásticos sino aplicar cluster. Esto también implica que debemos ser conscientes de que es muy probable que el supuesto de no-correlación  $E[e_i e_j] = 0$  no se cumpla, pues en este caso pueden haber factores no observados en cada salón que si correlacionen los resultados del estudiante  $i$  con el estudiante  $j$  que pertenecen al mismo salón, lo que vimos formalmente en clase como  $E[e_{gi} e_{gh}] \neq 0, \forall i \neq h$ . Por ejemplo, si el profesor de un salón específico se enferma o, por el contrario, posee una motivación excepcional independientemente de su raza, estos factores afectarán simultáneamente el término de error de todos los estudiantes de ese salón, generando una correlación intra-clúster que debe ser corregida.

## 2.2 Punto 2

**Por el momento, suponga que usted desea estimar el modelo sin intercepto:**

$$Y_i = \beta X_i + \varepsilon_i$$

**Nota:** Considere que es un modelo donde las variables  $Y$  y  $X$  se han re-centrado con respecto a sus medias. En general, note que eliminar el intercepto tiene consecuencias importantes si no se realiza dicho proceso.

**Donde  $X_i$  es una variable determinística. Determine la varianza del estimador de  $\beta$  bajo los siguientes escenarios:**

- **Caso 1: Se cumplen los supuestos de homocedasticidad y no-correlación del término de error.**

- Caso 2: Se cumple el supuesto de no-correlación, pero existe heterocedasticidad.
- Caso 3: Existe heterocedasticidad y correlación entre las características no-observadas de los individuos que asisten al mismo colegio.

Para cada caso, identifique el estimando población correspondiente y proponga un estimador adecuado de la varianza. Justifique brevemente su respuesta.

R/:

En primer lugar partamos de la definición de nuestro esmitado  $\hat{\beta}$ :

Nuestro modelo es:  $Y_i = \beta X_i + \varepsilon_i$

El problema de minimización es:

$$\min \sum_{i=1}^N (Y_i - \beta X_i)^2$$

Si obtenemos la FOC:

$$\frac{\partial SSR}{\partial \beta} = 2 \sum_{i=1}^N (Y_i - \beta X_i)(-X_i)$$

$$\sum_{i=1}^N (Y_i X_i - \hat{\beta} X_i^2) = 0$$

Despejando  $\hat{\beta}$ :

$$\sum_{i=1}^N (Y_i X_i) - \hat{\beta} \sum_{i=1}^N X_i^2 = 0$$

$$\hat{\beta} = \frac{\sum_{i=1}^N (Y_i X_i)}{\sum_{i=1}^N X_i^2}$$

Ahora veamos la varianza en cada uno de los casos:

- Caso 1: Se cumplen los supuestos de homocedasticidad y no-correlación del término de error.

el caso nos plantea que  $Var(e_i|X) = \sigma^2$  y que  $E[e_i e_j] = 0, \forall i \neq j$ .

Para encontrar la varianza primero organicemos remplazando  $Y_i$ :

$$\hat{\beta} = \frac{\sum_{i=1}^N ((\beta X_i + e_i) X_i)}{\sum_{i=1}^N X_i^2}$$

$$\hat{\beta} = \frac{\sum_{i=1}^N (\beta X_i^2 + e_i X_i)}{\sum_{i=1}^N X_i^2}$$

$$\hat{\beta} = \frac{\beta \sum_{i=1}^N X_i^2 + \sum_{i=1}^N e_i X_i}{\sum_{i=1}^N X_i^2}$$

$$\hat{\beta} = \beta + \frac{\sum_{i=1}^N e_i X_i}{\sum_{i=1}^N X_i^2}$$

Aplicamos el operador de la varianza condicional:

$$Var(\hat{\beta} | X) = \underbrace{Var(\beta)}_{Var(\text{constante})=0} + Var \left( \frac{\sum_{i=1}^N X_i e_i}{\sum_{i=1}^N X_i^2} \middle| X \right)$$

Aplicamos la propiedad de la varianza  $Var(aX+b) = a^2 Var(X)$  y que cuando hay distribución conjunta  $Var(A+B) = Var(A) + Var(B) + 2 \text{Cov}(A, B)$

$$Var(\hat{\beta}|X) = Var \left( \frac{\sum_{i=1}^N X_i e_i}{\sum_{i=1}^N X_i^2}; \middle| X \right)$$

$$Var(\hat{\beta}|X) = \frac{1}{\left( \sum_{i=1}^N X_i^2 \right)^2} Var \left( \sum_{i=1}^N X_i e_i; \middle| X \right)$$

$$Var(\hat{\beta}|X) = \frac{1}{\left( \sum_{i=1}^N X_i^2 \right)^2} \left[ \sum_{i=1}^N X_i^2 Var(e_i|X) + \sum_{i=1}^N \sum_{j \neq i}^N X_i X_j \underbrace{\text{Cov}(e_i e_j)}_0 \right]$$

$$Var(\hat{\beta}|X) = \frac{1}{\left( \sum_{i=1}^N X_i^2 \right)^2} \sum_{i=1}^N X_i^2 \underbrace{Var(e_i|X)}_{\sigma^2}$$

$$\text{Var}(\hat{\beta}|X) = \frac{\sigma^2}{\sum_{i=1}^N X_i^2}$$

Una vez obtenido nuestro estimador, como no conocemos  $\sigma^2$  usamos su estimador  $\hat{\sigma}^2$ . Por lo tanto nuestro estimador de la varianza es:

$$\widehat{\text{Var}}(\hat{\beta}) = \frac{\hat{\sigma}^2}{\sum_{i=1}^N X_i^2}$$

Donde:

$$\hat{\sigma}^2 = \frac{\sum_{i=1}^N e_i^2}{N - \underbrace{K}_{\text{en este caso} = 1}}$$

- **Caso 2:** Se cumple el supuesto de no-correlación, pero existe heterocedasticidad.

Este caso nos plantea que  $\text{Var}(e_i|X) = \sigma_i^2$  y que  $E[e_i e_j] = 0, \forall i \neq j$ . Entonces:

$$\begin{aligned} \text{Var}(\hat{\beta}|X) &= \frac{1}{\left(\sum_{i=1}^N X_i^2\right)^2} \left[ \sum_{i=1}^N X_i^2 \text{Var}(e_i|X) + \sum_{i=1}^N \sum_{i \neq j}^N X_i X_j \underbrace{\text{Cov}(e_i e_j)}_0 \right] \\ \text{Var}(\hat{\beta}|X) &= \frac{1}{\left(\sum_{i=1}^N X_i^2\right)^2} \sum_{i=1}^N X_i^2 \underbrace{\text{Var}(e_i|X)}_{\sigma_i^2} \\ \text{Var}(\hat{\beta}|x_i) &= \frac{1}{\left(\sum_{i=1}^N X_i^2\right)^2} \sum_{i=1}^N X_i^2 \sigma_i^2 \\ \text{Var}(\hat{\beta}|x_i) &= \frac{\sum_{i=1}^N X_i^2 \sigma_i^2}{\left(\sum_{i=1}^N X_i^2\right)^2} \end{aligned}$$

Por lo tanto el estimador de la varianza siguiendo la formulación de errores robustos de White es:

$$\widehat{\text{Var}}(\hat{\beta}) = \frac{\sum_{i=1}^N X_i^2 \hat{\sigma}_i^2}{\left(\sum_{i=1}^N X_i^2\right)^2}$$

Donde  $\hat{e}_i = (Y_i - \hat{\beta}X_i)$ . Es importante tener en cuenta que no podemos conocer la varianza de cada persona  $i$  por lo tanto hacemos una aproximación a través del residual estimado.

- **Caso 3:** Existe heterocedasticidad y correlación entre las características no-observadas de los individuos que asisten al mismo colegio.

Este caso nos plantea que  $\text{Var}(e_{gi}|X) = \sigma_{gi}^2$ , que existe correlación dentro de los grupos tal que  $E[e_{gi}e_{gj}] \neq 0$  para estudiantes del mismo colegio, pero hay independencia entre colegios  $E[e_{gi}e_{hj}] = 0$ .

entonces:

$$\hat{\beta} = \beta + \frac{\sum_{i=1}^N X_i e_i}{\sum_{i=1}^N X_i^2}$$

Como tenemos correlación al interior de los colegios, agrupamos la suma del numerador por grupos (colegios)  $g$ , en lugar de individuos  $i$ :

$$\hat{\beta} = \beta + \frac{\sum_{g=1}^G \left( \sum_{i \in g} X_{gi} e_{gi} \right)}{\sum_{i=1}^N X_i^2}$$

Aplicamos la varianza condicional recordando que  $E[e_{gi}e_{hj}] = 0$  y que la varianza de la suma es la varianza de cada grupo:

$$\text{Var}(\hat{\beta} | X) = \frac{\text{Var} \left( \sum_{g=1}^G \left( \sum_{i \in g} X_{gi} e_{gi} \right) | X \right)}{\left( \sum_{i=1}^N X_i^2 \right)^2}$$

$$\text{Var}(\hat{\beta} | X) = \frac{\sum_{g=1}^G \text{Var} \left( \sum_{i \in g} X_{gi} e_{gi} | X \right) + \sum_{g=1}^G \sum_{h \neq g} \text{COV} \left( X_{gi} e_{gi}, X_{hj} e_{hj} | X \right)}{\left( \sum_{i=1}^N X_i^2 \right)^2}$$

El término

$$\sum_{g=1}^G \sum_{h \neq g} \text{COV} \left( X_{gi} e_{gi}, X_{hj} e_{hj} | X \right) = 0$$

porque tenemos independencia entre colegios  $E[e_{gi}e_{hj}] = 0$

Entonces tenemos:

$$\text{Var}(\hat{\beta} | X) = \frac{\sum_{g=1}^G \text{Var} \left( \sum_{i \in g} X_{gi} e_{gi} \mid X \right)}{\left( \sum_{i=1}^N X_i^2 \right)^2}$$

Que es lo mismo que:

$$\text{Var}(\hat{\beta} | x_i) = \frac{\sum_{g=1}^G E \left[ \left( \sum_{i \in g} X_{gi} e_{gi} \mid X \right)^2 \right]}{\left( \sum_{i=1}^N X_i^2 \right)^2}$$

En este caso nuestro estimador sería:

$$\widehat{\text{Var}}(\hat{\beta} | X) = \frac{\sum_{g=1}^G \left( \sum_{i \in g} X_{gi} \hat{e}_{gi} \right)^2}{\left( \sum_{i=1}^N X_i^2 \right)^2}$$

Este estimador es el adecuado porque captura la estructura de correlación intra-clúster. Al elevar al cuadrado la suma a nivel de grupo, el estimador incorpora no solo la varianza individual (heterocedasticidad), sino también todas las covarianzas entre estudiantes del mismo colegio. Es importante notar que, aunque el tratamiento se asignó a nivel de salón, el supuesto del problema indica correlación de errores a nivel de colegio. Por lo tanto, para evitar subestimar la varianza, la variable de agrupación G corresponde a los colegios.

### 2.3 Punto 3

Uno de sus colegas le indica que no es necesario tener en cuenta el cluster a nivel de colegio y le propone usar la siguiente expresión como estimador de la varianza en el caso 3:

$$\frac{\sum_i \sum_j x_i x_j \hat{\varepsilon}_i \hat{\varepsilon}_j}{(\sum_i x_i)^2}$$

- Utilizando sus conocimientos de teoría de regresión lineal, explique brevemente por qué este estimador es inválido.
- Compare el estimador que usted propuso para el caso 3 con el que le propuso su colega. ¿Cómo soluciona su estimador el problema que identificó?

**R/:**

El estimador es inválido por dos motivos.

1). En primer lugar, el numerador colapsa matemáticamente a cero. Esto se puede notar al recordar que una propiedad fundamental de MCO es que los residuos son ortogonales a los regresores. Tengamos en cuenta que esa ortogonalidad viene del mismo proceso de minimización de cuadrados:

$$\min \sum_{i=1}^N (Y_i - \beta X_i)^2$$

FOC:

$$\frac{\partial SSR}{\partial \beta} = 2 \sum_{i=1}^N (Y_i - \beta X_i)(-X_i)$$

Igualando a cero para encontrar el mínimo:

$$\sum_{i=1}^N (X_i) \underbrace{(Y_i - \hat{\beta} X_i)}_{\hat{\varepsilon}_i} = 0$$

Lo que quiere decir que:

$$\sum_{i=1}^N X_i \hat{\varepsilon}_i = 0$$

Si tomamos el numerador propuesto

$$\sum_i \sum_j x_i x_j \hat{\varepsilon}_i \hat{\varepsilon}_j$$

y agrupamos las sumatorias:

$$\underbrace{\sum_i x_i \hat{\varepsilon}_i}_{0} \underbrace{\sum_j x_j \hat{\varepsilon}_j}_{0}$$

Por ortogonalidad, el numerador propuesto colapsaría a cero, resultando en una varianza estimada de cero.

2). En términos conceptuales, asume que existe correlación entre todos los individuos de la muestra, ignorando la independencia entre colegios  $E[e_{gi}e_{hj}] = 0$ .

Por su lado, nuestro estimador propuesto para el caso 3:

$$\widehat{\text{Var}(\hat{\beta})} = \frac{\sum_{g=1}^G (\sum_{i \in g} X_{gi} \hat{e}_{gi})^2}{\left( \sum_{i=1}^N X_i^2 \right)^2}$$

soluciona el problema porque ordena y agrupa las operaciones de manera correcta.

Para poder entender esto, centrémonos de nuevo el numerador  $\sum_{g=1}^G (\sum_{i \in g} X_{gi} \hat{e}_{gi})^2$ .

En primer lugar, calcula la suma de los productos cruzados para cada colegio  $g$ . En este caso, al ser la suma de cada colegio, se evita que la condición de ortogonalidad tenga efecto, pues no es la suma total de los productos; un colegio puede tener contribuciones positivas y otro negativas a los errores. Luego, al elevar eso al cuadrado, convertimos esos balances positivos y negativos en estrictamente positivos. Finalmente, aplicamos la sumatoria de todos los colegios, logrando así capturar la verdadera variabilidad intra-clúster y respetando la independencia entre colegios.

## 2.4 Punto 4

**¿Compare los estimadores robustos a heterocedasticidad (caso 2) y robustos a clusters (caso 3) que usted propuso. Para ello:**

- Explique por qué el estimador robusto a clusters también es robusto a heterocedasticidad.
- ¿Es razonable esperar que la varianza estimada mediante el estimador robusto a clusters sea mayor que la obtenida con el estimador robusto a heterocedasticidad? Justifique su respuesta.

**R/:**

Para responder a estas preguntas veamos los dos estimadores. El de errores robustos a heterocedasticidad:

$$\widehat{\text{Var}(\hat{\beta})}_{White} = \frac{\sum_{i=1}^N X_i^2 \hat{e}_i^2}{\left( \sum_{i=1}^N X_i^2 \right)^2}$$

Frente al de errores robustos por cluster:

$$\widehat{\text{Var}(\hat{\beta})}_{\text{Cluster}} = \frac{\sum_{g=1}^G \left( \sum_{i \in g} X_{gi} \hat{e}_{gi} \right)^2}{\left( \sum_{i=1}^N X_i^2 \right)^2}$$

Como se puede notar, ambos estimadores estiman la varianza de cada observación  $i$  por medio de  $\hat{e}_{gi}$  y  $\hat{e}_i$ . Es decir, ambos tienen en cuenta la heterocedasticidad, que significa una varianza diferente en los errores para cada valor de  $X$ .

Veámoslo más de cerca. Para ello, expandamos el numerador de nuestro estimador por cluster:

$$\sum_{g=1}^G \left( \sum_{i \in g} X_{gi} \hat{e}_{gi} \right)^2$$

Esto quedaría:

$$\sum_{g=1}^G \left[ \left( \sum_{i \in g} X_{gi}^2 \hat{e}_{gi}^2 \right) + \left( \sum_{i \in g} \sum_{j \in g, j \neq i} X_{gi} X_{gj} \hat{e}_{gi} \hat{e}_{gj} \right) \right]$$

Como se puede notar, el término de la izquierda es la expresión del estimador dos, que reconoce la heterocedasticidad.

Por otro lado, al verlo, se nota que es la parte del estimador de White **más** otra cosa, que representa la correlación intracluster. Por lo tanto, al permitir la correlación intracluster, solo viendo la ecuación podemos notar que la varianza va a ser mayor con el estimador de cluster.

**Habiendo adquirido una mayor claridad sobre la teoría detrás de los errores estándar clusterizados, usted procede a intentar replicar algunos de los resultados del trabajo de Gershenson et al. (2022), integrando los conocimientos sobre errores estándar clusterizados desarrollados en los incisos anteriores.**

En particular, recuerde que el experimento se llevó a cabo sobre estudiantes de kínder de raza negra y que la exposición a profesores de distinta raza fue aleatorizada *dentro de cada colegio*, asignando estudiantes y docentes a diferentes salones. Una ilustración intuitiva de este contexto puede verse en la serie *Abbott Elementary*, que retrata un colegio con una población estudiantil predominantemente negra cuyos docentes pertenecen a distintas razas. El experimento se implementó en múltiples condados y estados de E.E.U.U.

Bajo este diseño, los estudiantes de kínder de raza negra fueron expuestos de manera aleatoria a profesores de la misma raza o de razas distintas *condicional*

*en el colegio.* En consecuencia, haciendo uso de sus conocimientos sobre diseños experimentales, usted estima la siguiente ecuación:

$$Y_i = \beta_0 + \beta_1 D_i + \varepsilon_i.$$

## 2.5 Punto 5

Usando el caso estudio, identifique qué factores pueden generar una mayor varianza estimada por parte de los errores estándar clusterizados a nivel de colegio. Para ello:

- Usando el estimador que usted propuso en el caso 3 inciso 3, enuncie qué mecanismos matemáticos incrementan la varianza estimada.
- Por cada uno de los mecanismos hallados, dé un ejemplo concreto usando el contexto del caso estudio que lo respalde.
- Estime el modelo anterior utilizando como variable dependiente: i) el puntaje en matemáticas del SAT y ii) la probabilidad de ingresar a la universidad. Reporte los resultados en una tabla, incluyendo errores estándar robustos a heterocedasticidad y errores estándar clusterizados a nivel de colegio.

R/:

El estimador de cluster que obtuvimos fue

$$\widehat{\text{Var}(\hat{\beta})}_{\text{Cluster}} = \frac{\sum_{g=1}^G \left( \sum_{i \in g} X_{gi} \hat{e}_{gi} \right)^2}{\left( \sum_{i=1}^N X_i^2 \right)^2}$$

Matemáticamente existen dos mecanismos fundamentales que incrementan la varianza estimada: un aumento en el numerador o una disminución en el denominador. Veamos de qué consta el numerador:

$$\sum_{g=1}^G \left[ \left( \sum_{i \in g} X_{gi}^2 \hat{e}_{gi}^2 \right) + \left( \sum_{i \in g} \sum_{j \in g, j \neq i} X_{gi} X_{gj} \hat{e}_{gi} \hat{e}_{gj} \right) \right]$$

Como vimos anteriormente, el primer término representa la varianza de las observaciones individuales. Dicha varianza está compuesta de  $X_{gi}$  y de  $\hat{e}_{gi}$ , que representan respectivamente el valor de la variable independiente para el individuo  $i$  en el grupo o *cluster*  $g$  y su residuo

respectivo. Por lo anterior, la varianza se puede inflar matemáticamente si tenemos datos muy atípicos en  $X_{gi}$  o residuos muy grandes  $\hat{e}_{gi}$ .

En cuanto al segundo término, este representa la correlación intra-cluster. Si existe una alta correlación entre los individuos del mismo grupo, los productos cruzados en nuestra sumatoria serán grandes y positivos, incrementando significativamente la varianza.

Ahora veamos el denominador:

$$\left( \sum_{i=1}^N X_i^2 \right)^2$$

Representa el cuadrado de la variabilidad total de  $X$ . Funciona como un estabilizador, a mayor información, es decir, más datos o más dispersión en  $X$ , más grande es este denominador y más pequeña es la varianza y viceversa.

Aterraremos estos mecanismos al caso. En nuestro modelo con intercepto, la variable relevante es la versión centrada ( $D_i - \bar{D}$ )

Para derivar el estimador exacto en este contexto, partimos del problema de minimización:

$$\min_{\hat{\beta}_0, \hat{\beta}_1} \sum_{i=1}^N (Y_i - \hat{\beta}_0 - \hat{\beta}_1 D_i)^2$$

**FOC respecto de  $\hat{\beta}_0$ :**

$$-2 \sum_{i=1}^N (Y_i - \hat{\beta}_0 - \hat{\beta}_1 D_i) = 0$$

$$\sum_{i=1}^N Y_i - N\hat{\beta}_0 - \hat{\beta}_1 \sum_{i=1}^N D_i = 0$$

$$N\hat{\beta}_0 = \sum_{i=1}^N Y_i - \hat{\beta}_1 \sum_{i=1}^N D_i$$

Despejando  $\beta_0$ :

$$\hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{D}$$

**FOC respecto de  $\hat{\beta}_1$ :**

$$-2 \sum_{i=1}^N (Y_i - \hat{\beta}_0 - \hat{\beta}_1 D_i) D_i = 0$$

$$\sum_{i=1}^N (Y_i - (\bar{Y} - \hat{\beta}_1 \bar{D}) - \hat{\beta}_1 D_i) D_i = 0$$

$$\sum_{i=1}^N (Y_i - \bar{Y} + \hat{\beta}_1 \bar{D} - \hat{\beta}_1 D_i) D_i = 0$$

$$\sum_{i=1}^N [(Y_i - \bar{Y}) - (D_i - \bar{D}) \hat{\beta}_1] D_i = 0$$

$$\sum_{i=1}^N D_i (Y_i - \bar{Y}) - \hat{\beta}_1 \sum_{i=1}^N D_i (D_i - \bar{D}) = 0$$

Que es lo mismo que:

$$\sum_{i=1}^N (D_i - \bar{D})(Y_i - \bar{Y}) - \hat{\beta}_1 \sum_{i=1}^N (D_i - \bar{D})(D_i - \bar{D}) = 0$$

Por lo tanto depejando  $\hat{\beta}_1$ :

$$\hat{\beta}_1 = \frac{\sum_{i=1}^N (D_i - \bar{D})(Y_i - \bar{Y})}{\sum_{i=1}^N (D_i - \bar{D})^2}$$

$$\hat{\beta}_1 = \frac{\sum_{i=1}^N (D_i - \bar{D}) Y_i}{\sum_{i=1}^N (D_i - \bar{D})^2}$$

$$\hat{\beta}_1 = \beta_1 + \frac{\sum_{i=1}^N (D_i - \bar{D}) \varepsilon_i}{\sum_{i=1}^N (D_i - \bar{D})^2}$$

Si aplicamos la varianza condicional y permitimos la correlación dentro de los clusters:

$$\text{Var}(\hat{\beta}_1) = \frac{1}{\left(\sum_{i=1}^N (D_i - \bar{D})^2\right)^2} \text{Var} \left( \sum_{i=1}^N (D_i - \bar{D}) \varepsilon_i \right)$$

Entonces:

$$\widehat{\text{Var}(\hat{\beta})}_{\text{Cluster}} = \frac{\sum_{g=1}^G (\sum_{i \in g} (D_{gi} - \bar{D}) \hat{e}_{gi})^2}{\sum_{i=1}^N (D_i - \bar{D})^2}$$

Por lo tanto en el caso de nuestra regresión el numerador expandido, que captura los mecanismos de inflación de varianza, es:

$$\sum_{g=1}^G \left[ \left( \sum_{i \in g} (D_{gi} - \bar{D})^2 \hat{e}_{gi}^2 \right) + \left( \sum_{i \in g} \sum_{j \in g, j \neq i} (D_{gi} - \bar{D})(D_{gj} - \bar{D}) \hat{e}_{gi} \hat{e}_{gj} \right) \right]$$

Veamos, el primer mecanismo asociado a la varianza individual. Como ya mencionamos, se observa un incremento si hay factores residuales grandes no explicados por el tratamiento. Por ejemplo, un shock exógeno, como una ola de desempleo o divorcios en las familias de un grupo específico de estudiantes, aumentaría sus residuos individuales inflando la varianza total.

Por otro lado, en cuanto a la correlación intra-cluster, sabemos que a mayor correlación entre compañeros de colegio, mayor varianza. Supongamos que el colegio  $g = 1$  sufrió un fallo eléctrico y se quedó sin aire acondicionado durante los exámenes. Este factor ambiental afecta negativamente a todos los estudiantes de ese colegio simultáneamente. Sus errores estarán correlacionados positivamente, incrementando drásticamente el segundo término del numerador.

Por último, veamos como funcionaría el mecanismo del denominador, que en este caso sería:

$$\left( \sum_{i=1}^N (D_i - \bar{D})^2 \right)^2$$

Supongamos que en nuestra muestra solo tenemos 10 estudiantes tratados (con profesor de su misma raza) frente a miles de controles. En este caso, la variación  $(D_i - \bar{D})^2$  es mínima, lo que hace que el denominador sea muy pequeño. Al dividir por un número pequeño, la varianza resultante será muy grande, indicando que nos falta información para estimar el efecto con precisión.

Veamos la estimación de los modelos con errores robustos para heterocedasticidad y con cluster de errores estandar a nivel colegio:

```
#Cargando paquetes necesarios
library(haven)
library(fixest)
library(modelsummary)
```

```

library(dplyr)
library(kableExtra)

#Importando los datos para la estimación del modelo

race_teaching_1_ <- read_dta("race_teaching (1).dta")

#Haciendo las regresiones con errores heterocedasticos
Reg_Hete_SAT<-feols(sat_math ~ D, race_teaching_1_, vcov = "hetero")
Reg_Hete_Col<-feols(college ~ D, race_teaching_1_, vcov = "hetero")

#Haciendo las regresiones con cluster por colegio
Reg_Clus_SAT<-feols(sat_math ~ D, race_teaching_1_, vcov = ~ school )
Reg_Clus_Col<-feols(college ~ D, race_teaching_1_, vcov = ~ school)

#Haciendo tabla autocontendia

#Definimos el mapa de coeficientes y la información visible
mapa_coeficientes <- c("D" = "Profesor Misma Raza",
                        "(Intercept)" = "Media sin Tratamiento")
mapa_gof <- list(list("raw" = "nobs",
                      "clean" = "Observaciones", "fmt" = 0),
                  list("raw" = "r.squared",
                      "clean" = "R2", "fmt" = 3))

#Generamos la tabla
modelsummary(
  list(
    "(Robusto)" = Reg_Hete_SAT,
    "(Cluster)" = Reg_Clus_SAT,
    "(Robusto)" = Reg_Hete_Col,
    "(Cluster)" = Reg_Clus_Col
  ),
  coef_map = mapa_coeficientes,
  gof_map = mapa_gof,
  fmt = 3,
  stars = c('*' = .1, '**' = .05, "***" = .01),
  title = "Tabla 1. Efecto de la asignación racial docente",
  notes = list("Nota: Errores estándar entre paréntesis."),
  output = "kableExtra"
) %>%

```

```

add_header_above(c(" " = 1, "Puntaje SAT" = 2,
                  "Ingreso Universidad" = 2)) %>%
kable_styling(
  latex_options = c("hold_position",
                    "scale_down", "striped"),
  bootstrap_options = c("striped", "hover", "condensed"),
  full_width = FALSE,
  position = "center"
)

```

Table 1: Tabla 1. Efecto de la asignación racial docente

	Puntaje SAT		Ingreso Universidad	
	(Robusto)	(Cluster)	(Robusto)	(Cluster)
Profesor Misma Raza	4.607*** (0.064)	4.607*** (0.065)	0.198*** (0.003)	0.198*** (0.004)
Media sin Tratamiento	499.616*** (0.045)	499.616*** (0.319)	0.513*** (0.002)	0.513*** (0.010)
Observaciones	99 204	99 204	99 204	99 204
R <sup>2</sup>	0.050	0.050	0.041	0.041

\* p < 0.1, \*\* p < 0.05, \*\*\* p < 0.01

Nota: Errores estándar entre paréntesis.

## 2.6 Punto 6

¿Qué posible impacto puede tener un nivel de agregación más grande al clusterizar sobre la varianza estimada? Use como guía los siguientes puntos:

- Use el estimador de la varianza que usted propuso en el inciso 3, caso 3 y compare la varianza teórica que se obtiene al clusterizar por colegio vs por condado.
- Repita las estimaciones del inciso 5, concentrándose únicamente en la variable  $Y_i$  correspondiente al puntaje de matemáticas en la prueba SAT. Reporte los coeficientes estimados junto con errores estándar robustos a heterocedasticidad y errores estándar clusterizados a nivel de: i) salón, ii) colegio, iii) condado y iv) estado
- interprete los resultados obtenidos. ¿Las estimaciones son consistentes con lo que usted encuentra teóricamente?

### (Pendiente demostración matematica la hago después no se como hacerla)

Siguiendo a Angrist y Pischke y los apuntes de Hansen, y considerando que la unidad de colegio se encuentra anidada dentro de condado y este a su vez en estado, la teoría predice el comportamiento de la varianza. Siempre que exista una correlación intra-cluster positiva a un nivel superior (es decir, que los colegios dentro del mismo condado o estado compartan choques comunes), la varianza estimada clusterizada a estos niveles debería ser mayor que la varianza robusta o clusterizada a niveles inferiores

Respecto a la validez de esta inferencia, Angrist menciona que la corrección por cluster funciona adecuadamente cuando el número de grupos es suficientemente grande  $G \approx 42$ . Hansen advierte que con un  $G$  pequeño, los errores estándar clusterizados pueden volverse imprecisos y sufrir de un sesgo hacia abajo.

En la práctica econométrica, se sugiere clusterizar al nivel más agregado donde exista correlación de los errores o donde se haya asignado el tratamiento. Si al subir el nivel de clusterización los errores estándar aumentan, estamos corrigiendo un sesgo negativo y evitando falsos positivos. Por otro lado, si los errores estándar permanecen estables al subir de nivel, eso indica que no hay una correlación espacial a ese nivel. Sin embargo, consideramos que debe ser una buena práctica reportar estos niveles superiores como prueba de robustez por transparencia con los resultados.

Ahora veamos la estimación del modelo tomando como variable  $Y_i$  el puntaje en matemáticas en la prueba SAT usando errores robustos para heterocedasticidad y errores clusterizados a nivel de los modelos con errores robustos para heterocedasticidad y con cluster de errores standar a nivel i) colegio, ii) condado y iii) estado:

```
#Cargando paquetes necesarios
library(haven)
library(fixest)
library(modelsummary)
library(dplyr)
library(kableExtra)

#Importando los datos para la estimación del modelo

race_teaching_1_ <- read_dta("race_teaching_(1).dta")

#Haciendo las regresion con errores heterocedasticos
Reg_Hete<-feols(sat_math ~ D, race_teaching_1_, vcov = "hetero")

#Haciendo las regresiones con cluster por colegio
Reg_Clus_School<-feols(sat_math ~ D, race_teaching_1_, vcov = ~ school )
```

```

#Haciendo las regresiones con cluster por condado
Reg_Clus_County<-feols(sat_math ~ D, race_teaching_1_, vcov = ~ county )

#Haciendo las regresiones con cluster por estado
Reg_Clus_State<-feols(sat_math ~ D, race_teaching_1_, vcov = ~ state )

#Haciendo tabla autocontendia

#Definimos el mapa de coeficientes y la información visible
mapa_coeficientes <- c("D" = "Profesor Misma Raza",
                      "(Intercept)" = "Media sin Tratamiento")
mapa_gof <- list(list("raw" = "nobs",
                      "clean" = "Observaciones", "fmt" = 0),
                  list("raw" = "r.squared",
                      "clean" = "R2", "fmt" = 3))

#Generamos la tabla
modelsummary(
  list(
    "Robustos" = Reg_Hete,
    "Cluster Coelgio" = Reg_Clus_School,
    "Cluster Condado" = Reg_Clus_County ,
    "Cluster Estado" = Reg_Clus_State
  ),
  coef_map = mapa_coeficientes,
  gof_map = mapa_gof,
  fmt = 3,
  stars = c('*' = .1, '**' = .05, "***" = .01),
  title = "Tabla 1. Efecto de la asignación
racial docente en diferentes niveles cluster",
  notes = list("Nota: Errores estándar entre paréntesis."),
  output = "kableExtra"
) %>%
  add_header_above(c(" " = 1, "Puntaje SAT" = 4)) %>%
  kable_styling(
    latex_options = c("hold_position",
                     "scale_down", "striped"),
    bootstrap_options = c("striped", "hover", "condensed"),
    full_width = FALSE,
    position = "center"
)

```

)

Table 2: Tabla 1. Efecto de la asignación racial docente en diferentes niveles cluster

	Puntaje SAT			
	Robustos	Cluster Coelgio	Cluster Condado	Cluster Estado
Profesor Misma Raza	4.607*** (0.064)	4.607*** (0.065)	4.607*** (0.067)	4.607*** (0.060)
Media sin Tratamiento	499.616*** (0.045)	499.616*** (0.319)	499.616*** (0.683)	499.616*** (1.204)
Observaciones	99 204	99 204	99 204	99 204
R <sup>2</sup>	0.050	0.050	0.050	0.050

\* p < 0.1, \*\* p < 0.05, \*\*\* p < 0.01

Nota: Errores estándar entre paréntesis.

El resultado de nuestra estimación da cuenta de lo que dijimos anteriormente. El estimador puntual es idéntico en todos los casos 4.607 con el mismo nivel de significación estadística  $p < 0.001$ . También podemos ver que el error estándar aumenta a 0.065 cuando aplicamos cluster de colegio y a 0.067 cuando aplicamos cluster de condado. No obstante al agrupar por estado los errores estandar caen 0.060.

Entonces podemos decir que el incremento de colegio a condado da cuenta de la existencia de correlación positiva entre colegios del mismo condado, lo que nos indica que el cluster a nivel Condado sería la estimación más adecuada sobretodo si tenemos en cuenta que en nuestra muestra  $G > 500$  para el nivel de condado. Por su parte la disminución cuando se aplica cluster a nivel de estado seguramente tiene que ver con un sesgo en el cálculo de los errores asociado a un  $G = 50$  que si bien es superior al aproximado mencionado por Angrist, como explica Hansen en sus notas, aún hay mucho por aprender sobre el correcto nivel para aplicar la correcta clusterización de los errores estandar.

## 2.7 Punto 7

Usted decide escribirle a su amiga cercana [Susan Athey](#) para pedirle su opinión sobre el comentario hecho por el referee #2. Ella le envía un código en **R**:

```
#-----
# Housekeeping\\Codigo Susan
#-----

# Semilla para replicación.
```

```

set.seed(31416)

# Cargar las librerías necesarias.
library(sandwich)
library(lmtest)

# Parámetros de la simulación
#-----

# Número de individuos en la población.
n_population <- 1e7

# Número de colegios.
schools <- 100

# Número de estudiantes por colegio
stud_by_school <- n_population / schools

# Probabilidad de aparecer en la muestra.
p_sample <- 0.01

# Número de simulaciones.
n_sim <- 500

# Construir base de datos poblacional
#-----

# Base para la construcción.
population <- data.frame(id = 1:n_population)

# Determinar el tratamiento.
population$D <- rbinom(n_population,
                        size = 1, prob = 0.5)

# Determinar un colegio para cada individuo.
population$schools <- rep(1:schools,
                           each = stud_by_school)

# Determinar el efecto por colegio.
population$school_effect <- c(rep(1, n_population / 2),
                                rep(-1, n_population / 2))

```

```
# Construir la variable de resultado.
population$Y <- population$school_effect * population$D
+ runif(n_population)
```

Usando ese código, realice el siguiente procedimiento:

- Tome 1'000 muestras de la población de interés y estime el modelo usando errores estándar robustos a heterocedasticidad y clusterizados a nivel de colegio.
- Para cada una de las muestras, determine el intervalo de confianza al 95% usando ambos errores estándar.
- Para cada una de las muestras, determine si el intervalo de confianza “cubre” el cero (es decir, el intervalo de confianza incluye el cero). Note que, en la simulación, el efecto esperado es cero por construcción.
- Determine los errores estándar robustos a heterocedasticidad y clusterizados promedio.
- Determine el porcentaje de veces que los intervalos de confianza “cubren” el cero.
- Interprete sus resultados. ¿Es cierto que siempre es mejor clusterizar al nivel más agregado?

**R/:**

```
#| echo: true
#| results: 'hide'

#Tomando 1000 muestras y estimando modelos
#
library(fixest)

# Semilla para replicación, ponemos nuestra propia semilla :3.
set.seed(2896)

# Número de simulaciones.
n_sim1 <- 1000

#Definimos tamaño muestra.

Tamano_muestra <- n_population*p_sample

# Vectores para guardar resultados
se_robusto <- numeric(n_sim1)
```

```

se_cluster <- numeric(n_sim1)
betas      <- numeric(n_sim1)

#Construyendo bucle para hacer las estimaciones

for (i in 1:n_sim1) {
  indices <- sample(1:n_population, size = Tamano_muestra)
  MuestraTemporal<- population[indices, ]
  modelo<- feols(Y~D, data = MuestraTemporal)
  #guardamos los coeficientes
  betas[i] <- coef(modelo)["D"]
  #Guardamos los errores estandar
  se_robusto[i]<- se(modelo, se = "hetero")["D"]
  se_cluster[i]<- se(modelo, cluster= ~schools)["D"]
}
#(Para general el bucle se usó ayuda de la IA).

#-----
# Calculando Intervalos de Confianza
#-----

#Definimos valor critico

valor_critico <- 1.96

#Calculando Intervalo Para Errores Robustos
#Limite inferior = \hatBeta - 1.96*se_robusto
ci_robusto_inf <- betas - (valor_critico * se_robusto)
#Limite superior = \hatBeta + 1.96*se_robusto
ci_robusto_sup <- betas + (valor_critico * se_robusto)

#Calculando Intervalos Para Errores Cluster
#Limite inferior = \hatBeta - 1.96*se_cluster
ci_cluster_inf <- betas - (valor_critico * se_cluster)

#Limite superior = \hatBeta + 1.96*se_cluster
ci_cluster_sup <- betas + (valor_critico * se_cluster)

#-----
# Calculando si los intervalos cubren cero
#-----

```

```

cubre_cero_robusto <- (ci_robusto_inf <= 0) & (ci_robusto_sup >= 0)
cubre_cero_cluster <- (ci_cluster_inf <= 0) & (ci_cluster_sup >= 0)

#
#-----#
#Calculando promedio de errores para los dos casos
#
Media_se_robusto<-mean(se_robusto)
Media_se_cluster<-mean(se_cluster)

```

Consolidando resultados en la tabla sugerida:

```

##Creando tabla
library(kableExtra)
library(dplyr)

#Haciedno Data Frame
tabla_final <- data.frame(
  media_rob = Media_se_robusto,
  procent_cobertura_rob   = mean(cubre_cero_robusto) * 100,
  media_clus = Media_se_cluster,
  porcent_cobertura_clus  = mean(cubre_cero_cluster) * 100
)

tabla_final %>%
  kbl(
    col.names = c("V Promedio", "% Cobertura", "V Promedio", "% Cobertura"),
    digits = 4,
    caption = "Tabla 1: Cobertura teórica de heterocedasticidad vs clusters",
    align = "c",
    booktabs = TRUE
  ) %>%
  add_header_above(c("Heterocedasticidad" = 2, "Cluster" = 2)) %>%
  kable_styling(
    latex_options = c("hold_position", "scale_down", "striped"),
    bootstrap_options = c("striped", "hover", "condensed"),
    full_width = FALSE,
    position = "center"
  )

```

Table 3: Tabla 1: Cobertura teórica de heterocedasticidad vs clusters

Heterocedasticidad		Cluster	
V Promedio	% Cobertura	V Promedio	% Cobertura
0.0045	94.5	0.1006	100

Como podemos notar, el promedio de los errores estándar clusterizados es considerablemente mayor al promedio de los robustos. Esto ocurre porque los primeros capturan la correlación de los errores a nivel de colegio, evitando así la subestimación del error estándar, evitando que cometamos error tipo 1. En cuanto a la cobertura, los intervalos clusterizados incluyeron el cero el 100% de las veces, lo que confirma que son más conservadores y adecuados ante la heterogeneidad de los colegios.

Frente a la pregunta de si siempre es mejor clusterizar al nivel más agregado, la respuesta no es unívoca. Si bien clusterizar a un nivel agregado es necesario para reconocer la estructura de correlación y evitar falsos positivos, esto depende crucialmente del número de grupos ( $G$ ) disponibles. Como sugiere la literatura, con un  $G$  muy pequeño los estimadores de varianza clusterizados se vuelven sesgados e inestables, haciendo que nuestros tests de hipótesis sean poco confiables.

## 2.8 Punto 8

**¿Considera usted que el referee #2 tiene razón? Escriba una breve respuesta a este comentario teniendo en cuenta los resultados del inciso anterior.**

**Comentario referee #2:** “No queda claro por qué los autores se limitan a clusterizar los errores estándar a nivel de colegio cuando disponen de información que permitiría hacerlo a niveles más agregados, como el condado o el estado. En muestras grandes como la suya, aumentar el nivel de agregación rara vez es problemático y puede ofrecer una inferencia más conservadora. Como regla práctica, recomendaría siempre reportar errores estándar clusterizados al nivel más agregado, en lugar de decidir ex-ante si se debe clusterizar y evitar pensar en la existencia de un nivel apropiado.”.

**R/:** El comentario del referee es válido parcialmente pero su regla práctica es incorrecta. Si bien tiene razón en que la clusterización captura la correlación intra-grupo y previene errores tipo 1, siendo una aproximación más conservadora que los errores robustos como evidenciamos en nuestra simulación, sugerir **siempre clusterizar al nivel más agregado y evitar pensar en el nivel apropiado** ignora los supuestos asintóticos.

Esta aproximación conservadora resultó conveniente en nuestra investigación a nivel de colegio e incluso de condado. Como observamos en las regresiones del punto 6, en esos niveles se cuenta con un número de grupos ( $G$ ) lo suficientemente grande para que la inferencia sea válida.

Sin embargo, elevar la agregación arbitrariamente al nivel de estado demostró ser perjudicial. A ese nivel, el número de grupos  $G$  cae al límite inferior recomendado por la literatura. Como evidenció nuestra regresión, esto genera inconsistencias y, en este caso específico, terminó subestimando los errores estándar en lugar de hacerlos más conservadores. Por lo tanto, el nivel de clusterización no debe elegirse a ciegas hacia arriba, sino que debe responder al diseño del muestreo a la asignación del tratamiento y la cantidad de grupos  $G$  que se tienen para aplicar el cluster.

### 3 Tercer Ejercicio

Los experimentos aleatorizados controlados (RCTs, por sus siglas en inglés) se han consolidado como el estándar para la evaluación de políticas públicas y programas de desarrollo. A diferencia de los estudios observacionales, los RCTs permiten establecer relaciones causales mediante la aleatorización del tratamiento, lo cual elimina el sesgo de selección y garantiza que las diferencias observadas entre grupos sean atribuibles únicamente a la intervención evaluada. No obstante, la credibilidad de estos estudios depende de manera crítica de la **replicabilidad**: la capacidad de otros investigadores de reproducir los resultados utilizando los mismos datos y métodos.

El estudio de [Dupas et al. \(2025\)](#), publicado en la *American Economic Review*, implementa un RCT a gran escala en Burkina Faso con 14,545 mujeres distribuidas en 499 aldeas, 100 centros de salud y 20 provincias, empleando múltiples niveles de aleatorización y estratificación. Los resultados desafían décadas de políticas públicas: **el acceso completamente gratuito a anticonceptivos no redujo la fecundidad ni incrementó su uso**. Este hallazgo nulo tiene profundas implicaciones para programas de desarrollo que representan miles de millones de dólares en inversión. Dada la naturaleza contraintuitiva de estos resultados, resulta particularmente valioso comprender cómo los investigadores garantizaron la robustez de sus conclusiones, desde el diseño experimental hasta el análisis de datos. Este ejercicio le permitirá verificar la replicabilidad de los resultados principales del estudio de [Dupas et al. \(2025\)](#). Para ello, deberá familiarizarse tanto con el artículo como con su paquete de replicación. Se recomienda enfáticamente la lectura del texto original para facilitar la solución de este ejercicio, a la hora de evaluar sus respuestas vamos a buscar evidencia de lo anterior.

**Datos disponibles:** Para este ejercicio utilizará muestras aleatorias del 60% de los datos originales, porque el resto se perdieron (vamos a asumir esto para el ejercicio):

- `baseline_sample.dta`: Muestra del 60% de la encuesta de línea base (primavera 2018).
- `endline_sample.dta`: Muestra emparejada del 60% de la encuesta de seguimiento (primavera 2021). Menor N que `baseline` debido a atrición.

- `listing_sample.dta`: Censo de hogares en las aldeas incluidas en la muestra.
- Puede usar el `codebook.xlsx` del paquete de replicación para identificar las variables.

### 3.1 Punto 1

1. **Diseño experimental:** Antes de poder verificar los resultados de un estudio, es fundamental entender cómo fue diseñado e implementado el experimento. El diseño experimental no solo determina qué preguntas pueden responderse, sino también qué supuestos son necesarios para la identificación causal y qué amenazas a la validez interna deben considerarse.

**Describa el diseño experimental del estudio de Dupas et al. (2025). Explique cómo fue implementada la aleatorización (incluyendo los diferentes niveles y la estratificación), qué tratamientos fueron aleatorizados y los principales desafíos metodológicos que enfrentaron los autores durante la implementación del estudio. (máx. 300 palabras)**

En la investigación entregaron cupones válidos por tres años que cubrían el 100% (subsidio total) o el 10% (grupo de comparación) del costo de cualquier método anticonceptivo moderno y servicios médicos asociados. Dado que los autores sospechaban que el costo financiero podría no ser la única barrera, introdujeron intervenciones para corregir fricciones de información en la demanda. Por un lado, proveyeron infografías sobre las tasas de mortalidad infantil locales para corregir la sobreestimación del riesgo de muerte suponiendo que al notar que la supervivencia había mejorado las familias no sentirían la necesidad de tener tantos hijos. Por otro lado, organizaron reuniones comunitarias con debates públicos y proyecciones audiovisuales para desafiar las normas sociales a favor de la natalidad y para tramitar los estigma frente a la anticoncepción.

El diseño experimental consistió en tres niveles de aleatorización, empleando diferentes niveles de estratificación. En el primer nivel, se aleatorizaron 100 centros de salud, estratificando por provincia: 50 centros fueron asignados al subsidio total (100%) y los otros 50 al grupo de comparación con el subsidio del 10%. En el segundo nivel, se seleccionaron 5 aldeas por cada centro de salud (en torno a cada centro había aproximadamente 10), abarcando un total de 500 aldeas. Estratificando por centro de salud, tres de estas aldeas se asignaron a intervenciones grupales y dos a intervenciones individuales. Finalmente, en el tercer nivel y dentro de las aldeas de intervención individual, los hogares se aleatorizaron (estratificando por aldea) en tres brazos: información sobre mortalidad infantil, proyección privada del video de edu-entretenimiento, o un grupo de control puro. A través de este diseño lograron aislar los efectos estimando así el efecto del subsidio, de las intervenciones de demanda por sí solas, y el efecto del subsidio cuando se combina con las intervenciones de demanda.

La implementación enfrentó tres principales obstáculos. En primer lugar la pandemia Covid-19 pospuso la recolección final de los datos, pues se tenía planeado el cierre a 2020 y se vieron obligados a ampliar un año. Además, en 2020 el gobierno de Burkina Faso anunció el

lanzamiento de una política de planificación familiar gratis. Adicionalmente en 2019 se presentó un paro de trabajadores de la salud, sin embargo reportaron que esto no afectó la provisión de servicios de acuerdo con el reporte de sus encuestas de monitoreo donde encontraron que el 92% de los centros de salud del experimento no presentaron falta de atención a los pacientes por estos motivos. Por último, cuatro centros de salud de la muestra fueron cerrados debido a condiciones de inseguridad.

### 3.2 Punto 2

- Defina formalmente la variable de asignación al tratamiento de subsidio ( $D_i$ ) donde  $i$  indexa a cada mujer. Presente los posibles valores que puede tomar esta variable.
- Defina los resultados potenciales para la variable de interés principal:  $Y_i = \text{tuvo al menos un nacimiento durante los 3 años del estudio}$ . ¿Cuántos resultados potenciales existen para cada mujer?
- Los autores decidieron que el grupo “control” recibiera un subsidio del 10% en lugar de no recibir nada. ¿Por qué esta decisión tiene sentido desde una perspectiva ética? ¿Qué parámetro causal están estimando entonces? (máx. 100 palabras)

R/:

- Definiendo formalmente la variable de asignación al tratamiento de subsidio

$$D_i = \begin{cases} 1 & \text{si la mujer } i \text{ fue asignada a recibir un subsidio del 100\%} \\ 0 & \text{si la mujer } i \text{ fue asignada a recibir un subsidio del 10\%} \end{cases}$$

- Definiendo los resultados potenciales

$$Y_i = \begin{cases} Y_i(1) & \text{si } D_i = 1 \text{ (fue asignada al subsidio del 100\%)} \\ Y_i(0) & \text{si } D_i = 0 \text{ (fue asignada al subsidio del 10\%)} \end{cases}$$

Para cada mujer solo existe un resultado potencial que vemos de la siguiente manera:

$$Y_i = Y_i(1)D_i + (1 - D_i)Y_i(0)$$

- La decisión ética busca mitigar la injusticia de no otorgar nada a las mujeres del grupo control. El subsidio del 10% garantiza que todas las participantes obtengan una mejora en su acceso a la salud y actúa como reconocimiento por su tiempo al responder las encuestas. En este sentido, el efecto debe interpretarse estrictamente como el efecto marginal de ofrecer un subsidio completo frente a un subsidio pequeño como lo señalan en el paper.

### 3.3 Punto 3

- Liste los tres supuestos principales necesarios para identificar el efecto causal del subsidio completo sobre fecundidad. Incluya las expresiones matemáticas para aquellos supuestos que sea posible.
- La aleatorización fue estratificada por provincia. Escriba matemáticamente el supuesto de independencia condicional apropiado para este diseño.

R/:

- El primer supuesto es la independencia de los resultados potenciales. Esto implica que la asignación del tratamiento ( $D_i$ ), ya sea el subsidio del 100% o del 10%, es estadísticamente independiente de los resultados potenciales de la mujer  $i$ . En otras palabras, la asignación se comporta como si fuera completamente aleatoria, garantizando que las mujeres en ambos grupos son comparables y no hay características preexistentes que determinen quién recibe qué subsidio

$$(Y_i(1), Y_i(0)) \perp\!\!\!\perp D_i$$

El segundo supuesto es el de no spillovers, lo que quiere decir que el resultado potencial de la mujer  $i$  depende únicamente de si ella recibió el subsidio del 100% o del 10%, y no de la asignación que recibieron sus vecinas o amigas en la comunidad.

$$Y_i(D_i, D_{-i}) = Y_i(D_i)$$

El tercer supuesto es la consistencia en el tratamiento. Es decir Garantiza que el resultado empírico que observamos en los datos corresponde exactamente al resultado potencial del tratamiento y no a una doisificación del mismo.

- Este sería el supuesto de infependencia conficional

$$(Y_i(1), Y_i(0)) \perp\!\!\!\perp D_i | X_i$$

Lo que implica que:

$$E[Y_i | D_i, X_i] = E[Y_i | X_i]$$

### 3.4 Punto 4

Los autores reportan pruebas de balance en la Tabla A.1 del Apéndice. Su tarea es replicar el Panel A (características de las mujeres) utilizando `baseline_sample.dta`, una muestra aleatoria del 60% de los datos originales.<sup>1</sup>

1. Construya las variables analíticas necesarias para replicar las siguientes variables de la Tabla A.1:

- Edad de la mujer
- La mujer reporta que su esposo es polígame
- Número total de hijos deseados por la mujer
- Uso actual de anticoncepción moderna
- La necesidad de la mujer por anticonceptivos está insatisfecha
- No podría pagar por anticonceptivos si quisiera usarlos
- El hogar tiene radio

2. Para cada una de las siete variables, estime una regresión de balance de la forma:

$$X_i = \alpha + \beta \cdot \text{Tratamiento}_i + \gamma_{\text{provincia}} + \varepsilon_i,$$

con errores estándar agrupados (clusterizados) a nivel de centro de salud.

Para cada variable reporte:

- (i) el coeficiente del tratamiento,
- (ii) el error estándar entre paréntesis,
- (iii) el valor-p,
- (iv) la media del grupo control y
- (v) el tamaño de muestra ( $N$ ).

Calcule además el estadístico  $F$  conjunto (y su valor-p) para la hipótesis de que todos los coeficientes son iguales a cero.

3. Compare sus resultados con la Tabla A.1 del paper. ¿Hay evidencia de desbalance entre tratamiento y control? ¿Qué concluye sobre la correcta implementación

---

<sup>1</sup>Sus resultados serán similares pero no idénticos a los del paper debido al tamaño muestral.

de la aleatorización?

(máx. 150 palabras)

4. Analice las estadísticas descriptivas de la muestra. ¿Qué nos dicen sobre la población estudiada y sobre la plausibilidad y dirección del efecto esperado del tratamiento? Interprete.

(máx. 200 palabras).

R/:

```
#| message: false
#| warning: false
#Cargando librerias
library(haven)
library(dplyr)
library(fixest)
library(kableExtra)

#Cargando los datos

baseline_sample_ <- read_dta("baseline_sample.dta")

#Nombrando las variables

baseline_sample_<- baseline_sample_ %>%
  mutate(
    Edad_Mujer = an_bw_s3q5_age,
    Esposo_polygamo = an_bw_polygamous,
    N_Hijos_desados= an_bw_s8q1_childdesired,
    Uso_Actual_Anticoncep_Moderna = an_bw_modern_cmeth_curr_s11q5,
    Insatisfaccion_Acceso_Anticoncep = an_unmet,
    No_puede_pagar_anticoncep= an_able_contra,
    Hogar_Con_Radio=bw_s2q19a_radioyn,
    D_i= arm_free,
    Centro_Salud = new_csp
  )

#Estimando las regresiones

reg1<-feols(Edad_Mujer~ D_i | PROVINCE ,
             baseline_sample_, vcov = ~ Centro_Salud )
reg2<-feols(Esposo_polygamo~ D_i | PROVINCE ,
             baseline_sample_, vcov = ~ Centro_Salud )
```

```

reg3<-feols(N_Hijos_desados~ D_i | PROVINCE ,
             baseline_sample_, vcov = ~ Centro_Salud )
reg4<-feols(Uso_Actual_Anticoncep_Moderna~ D_i | PROVINCE ,
             baseline_sample_, vcov = ~ Centro_Salud )
reg5<-feols(Insatisfaccion_Acceso_Anticoncep~ D_i | PROVINCE ,
             baseline_sample_, vcov = ~ Centro_Salud )
reg6 <- feols(No_puede_pagar_anticoncep~ D_i | PROVINCE ,
               baseline_sample_, vcov = ~ Centro_Salud )
reg7 <- feols(Hogar_Con_Radio~ D_i | PROVINCE ,
               baseline_sample_, vcov = ~ Centro_Salud )

#Calculando estadistico F conjunto
reg_f <- feols(D_i ~ Edad_Mujer + Esposo_poligamo
                + N_Hijos_desados +
                  Uso_Actual_Anticoncep_Moderna
                + Insatisfaccion_Acceso_Anticoncep +
                  No_puede_pagar_anticoncep
                + Hogar_Con_Radio | PROVINCE,
                data = baseline_sample_,
                vcov = ~ Centro_Salud)

invisible(capture.output(test_conjunto <- wald(reg_f)))
f_stat <- test_conjunto$stat
f_pval <- test_conjunto$p

#Se revisó en el material de replicación
#se identificó que el cluster por new_cspes corresponde a centro de salud
#en el codebook no era claro.

# Preparando vectores para la tabla
modelos <- list(reg1, reg2, reg3, reg4, reg5, reg6, reg7)
var_nombres <- c("Edad de la mujer",
                 "La mujer reporta que su esposo es polígamo",
                 "Número total de hijos deseados por la mujer",
                 "Uso actual de anticoncepción moderna",
                 "Necesidad de la mujer por anticonceptivos está insatisfecha",
                 "No podría pagar por anticonceptivos si quisiera usarlos",
                 "El hogar tiene radio")
var_datos <- c("Edad_Mujer", "Esposo_poligamo", "N_Hijos_desados",
               "Uso_Actual_Anticoncep_Moderna", "Insatisfaccion_Acceso_Anticoncep",
               "No_puede_pagar_anticoncep", "Hogar_Con_Radio")

```

```

# Creando matriz vacia para llenarla con un loop
resultados <- matrix(ncol = 6, nrow = 0)

# --- Loop Corregido ---
for(i in 1:7) {
  m <- modelos[[i]]
  v <- var_datos[i]

  # Medias grupo control y tratamiento
  media_c <- mean(baseline_sample_[[v]][baseline_sample_$.D_i == 0], na.rm = TRUE)
  media_t <- mean(baseline_sample_[[v]][baseline_sample_$.D_i == 1], na.rm = TRUE)

  # EXTRACCIÓN SEGURA: Sacamos la tabla de coeficientes del modelo
  tabla_coefs <- summary(m)$coeftable
  coef_val <- tabla_coefs["D_i", "Estimate"]
  se_val   <- tabla_coefs["D_i", "Std. Error"]
  pval_val <- tabla_coefs["D_i", "Pr(>|t|)"]

  # Fila 1: Coeficiente e info
  fila_coef <- c(var_nombres[i],
                  round(media_c, 3),
                  round(media_t, 3),
                  nobs(m),
                  round(coef_val, 3),
                  round(pval_val, 3))

  # Fila 2: Error Estandar
  fila_se <- c("", "", "", "", paste0("(", round(se_val, 3), ")"), "")

  resultados <- rbind(resultados, fila_coef, fila_se)
}

# Agregando el F al final de la matriz
resultados <- rbind(resultados,
                      c("", "", "", "", "", ""),
                      c("Estadístico F conjunto", "", "", "", round(f_stat, 3), round(f_pval, 3)))

# Convirtiendo a data.frame garantizando que todo sea texto/número simple
tabla_df <- as.data.frame(resultados, row.names = FALSE)
names(tabla_df) <- c("Variable", "Control", "Tratamiento", "N", "Coeficiente / (EE)", "Valor")

# 3. Construir y estilizar la tabla con kableExtra

```

```

tabla_balance <- tabla_df %>%
  kbl(
    col.names = c("Variable", "Control", "Tratamiento", "N", "Coeficiente / (EE)", "Valor-p"),
    align = c("l", "c", "c", "c", "c", "c"),
    caption = "Tabla A.1: Pruebas de balance en la encuesta de línea base",
    booktabs = TRUE
  ) %>%
  add_header_above(c(" " = 1, "Medias (Línea Base)" = 2, " " = 1, "Diferencias" = 2)) %>%
  kable_styling(
    latex_options = c("hold_position", "scale_down"),
    bootstrap_options = c("hover", "condensed"),
    full_width = FALSE,
    position = "center"
  ) %>%
  footnote(
    general = "EE agrupados a nivel de centro de salud entre paréntesis.",
    general_title = "Nota: ",
    footnote_as_chunk = TRUE
  )
)

```

tabla\_balance

Table 4: Tabla A.1: Pruebas de balance en la encuesta de línea base

Variable	Medias (Línea Base)			Diferencias	
	Control	Tratamiento	N	Coeficiente / (EE)	Valor-p
Edad de la mujer	28.256	28.307	8687	0.095 (0.149)	0.523
La mujer reporta que su esposo es polígamo	0.437	0.472	8689	0.028 (0.02)	0.161
Número total de hijos deseados por la mujer	5.969	6.064	7855	0.083 (0.064)	0.201
Uso actual de anticoncepción moderna	0.324	0.303	8680	-0.013 (0.013)	0.331
Necesidad de la mujer por anticonceptivos está insatisfecha	0.385	0.39	8682	0.004 (0.014)	0.807
No podría pagar por anticonceptivos si quisiera usarlos	0.381	0.426	7873	0.036 (0.017)	0.034
El hogar tiene radio	0.478	0.486	8686	0.02 (0.02)	0.311
Estadístico F conjunto				1.673	0.111

*Nota:* EE agrupados a nivel de centro de salud entre paréntesis.

- Comparando resultado tablas:

Al comparar el resultado de la tabla de balanceo de nuestra muestra con la tabla original, observamos que los resultados son consistentes. A pesar de utilizar solo el 60% de la muestra, las medias capturan la misma tendencia.

En nuestro caso, casi todas las variables presentan un valor  $p > 0.10$ , lo que indica que no existen diferencias estadísticamente significativas entre los grupos. No obstante, se identificó que la variable que responde a “No podría pagar por anticonceptivos” sí mostró una diferencia estadísticamente significativa, lo cual también se evidencia en la tabla del estudio original.

Es importante tener en cuenta que, al evaluar múltiples variables, es esperable que alguna resulte significativa por puro azar. Esto puede corregirse fácilmente si se controla por la variable que no está balanceada. Sin embargo, también es válido señalar que esta situación puede generar dudas: si existe una variable observada desbalanceada, ¿cómo podemos estar seguros de que las variables no observadas también están balanceadas?

Por último, nuestra prueba definitiva es el estadístico F de significancia conjunta, que con un  $p = 0.111$  confirma que las características  $X$ , en conjunto, no predicen la asignación al grupo. Se puede concluir que no hay evidencia de desbalance sistemático y que la aleatorización fue implementada correctamente.

- **Analizando estadísticas descriptivas:**

Las estadísticas descriptivas de nuestra muestra muestran que las mujeres tienen, en promedio, 28 años y desean tener 6 hijos. Sin embargo, solo aproximadamente el 30% utiliza métodos anticonceptivos modernos, aproximadamente el 38% manifiesta tener una demanda insatisfecha de anticonceptivos modernos y entre el 38% y el 42% aproximadamente señala que no podría pagarlos.

Dado que se trata de mujeres en edades de alta fertilidad, que además expresan una demanda insatisfecha y dificultades para cubrir el costo de los anticonceptivos, es razonable esperar que aumente significativamente el uso de anticonceptivos modernos y, en consecuencia, al eliminar esta barrera mediante un subsidio del 100% para las mujeres tratadas, el número de hijos nacidos después de la intervención sea menor. Como vimos en el resultado del paper esta intención resultó no ser cierta.

### **3.5 Punto 5**

- **Replicación de Resultados Principales - Tabla 2:**

Use `baseline_sample.dta` y `endline_sample.dta`. Tenga en cuenta que el `endline` tiene menos observaciones debido a la atracción de las participantes.

**1. Construya las variables de resultado, realice el merge entre bases y reporte la tasa de atracción (total y por grupo de tratamiento). Reporte la atracción como tasas (%) y como número de observaciones (N).**

2. Escriba la ecuación econométrica que estima el efecto ITT del subsidio sobre fecundidad. Identifique claramente todos los componentes del modelo.

3. Estime el efecto ITT del subsidio (100% vs 10%) para los cuatro resultados principales. Replique la Tabla 2 del artículo (sin contar la columna 4).

R/:

```
#Cargando Librerias

library(dplyr)
library(haven)
library(fixest)
library(kableExtra)

#Cargando los datos

baseline<- read_dta("baseline_sample.dta")
endline <- read_dta("endline_sample.dta")

#Haciendo el merge de las bases y calculando atrición
#Seleccionando vars Endline

endline_listo <- endline %>%
  mutate(estuvo_endline = 1) %>%
  select(
    new_womid_final,
    estuvo_endline,
    an_ew_any_deliveries_ab_s7q4,
    an_ew_at_least_1preg_ab,
    an_ew_contra_modern_1st3y,
    an_ew_coupon_use_s15q7,
    ew_survey_date,
  )

# Uniendo
datos_completos <- baseline %>%
  left_join(endline_listo, by = "new_womid_final")
datos_completos <- datos_completos %>%
  mutate(atracion = ifelse(is.na(estuvo_endline), 1, 0))

datos_completos <- datos_completos %>%
  mutate(
    Y1_nacimiento = an_ew_any_deliveries_ab_s7q4,
```

```

Y2_embarazo = an_ew_at_least_1preg_ab,
Y3_uso_anti = an_ew_contra_modern_lst3y,
Y4_cupon     = an_ew_coupon_use_s15q7,
D_i          = arm_free
)

# Atricón por grupo de tratamiento
atricion_grupos <- datos_completos %>%
  group_by(D_i) %>%
  summarise(
    `N Inicial` = n(),
    `N Atricón` = sum(atricion),
    `Tasa de Atricón (%)` = round(mean(atricion) * 100, 2)
  ) %>%
  mutate(Grupo = ifelse(D_i == 1, "Tratamiento (100%)", "Control (10%)")) %>%
  select(Grupo, `N Inicial`, `N Atricón`, `Tasa de Atricón (%)`)

# Atricón Total
atricion_total <- datos_completos %>%
  summarise(
    Grupo = "Total Muestra",
    `N Inicial` = n(),
    `N Atricón` = sum(atricion),
    `Tasa de Atricón (%)` = round(mean(atricion) * 100, 2)
  )

# Unimos las filas para crear la tabla final
tabla_atricion <- bind_rows(atricion_grupos, atricion_total)

#generando tabla

# Generamos la tabla para el PDF con kableExtra
tabla_atricion %>%
  kbl(
    caption = "Tasa de Atricón entre Línea Base y Seguimiento",
    align = c("l", "c", "c", "c"),
    booktabs = TRUE
  ) %>%
  kable_styling(
    latex_options = "hold_position",
    bootstrap_options = "condensed",
    full_width = FALSE

```

)

Table 5: Tasa de Atracción entre Línea Base y Seguimiento

Grupo	N Inicial	N Atracción	Tasa de Atracción (%)
Control (10%)	4376	551	12.59
Tratamiento (100%)	4313	649	15.05
Total Muestra	8689	1200	13.81

- **Escribiendo la ecuación econometrica que identifica el efecto ITT del subsidio sobre fecundidad:**

La estimación del efecto de intencion del tratamiento (ITT) del del subsidio en el paper es:

$$Y_{ivcp} = \beta_1 SubsidioCompleto_c + \gamma_p + X'_{iv}\rho + \varepsilon_{ivcp}$$

Donde:

- $Y_{ivcp}$  es la variable de resultado, por ejemplo: por ejemplo, si tuvo un embarazo, si tuvo un nacimiento o si usó anticoncepción moderna en los últimos 3 años para la mujer  $i$ , residente en la aldea  $v$ , perteneciente al área de influencia del centro de salud  $c$ , ubicado en la provincia  $p$ .
- $SubsidioCompleto_c$  es la variable de tratamiento. Toma el valor de 1 si el centro de salud  $c$  fue asignado aleatoriamente al grupo que ofrece el subsidio completo y 0 si fue asignado al grupo de comparación que ofrece el subsidio parcial. En ese sentido  $\beta_1$  captura el efecto del tratamiento.
- $\gamma_p$  Efectos fijos a nivel de provincia.
- $X'_{iv}$  Es un vector de covariables de control a nivel individual (i) y de aldea (v). Incluye controles del seguimiento como la fecha de la encuesta y si fue telefónica y características de la línea base como edad, brecha de edad con el esposo, si es una unión polígama, hijos deseados, uso previo de anticonceptivos, escolaridad, entre otros. En línea con esto  $\rho$  representa el vector de coeficientes asociados a la covariables.
- Por último  $\varepsilon_{ivcp}$  representa el error idiosincratico. En este caso los errores estandar se clusterizan a nivel de centro de salud  $c$
- **Estime el efecto ITT del subsidio (100% vs 10%) para los cuatro resultados principales**

```

# Cargando librerías
library(dplyr)
library(haven)
library(fixest)
library(modelsummary)
library(kableExtra)

# Definimos el vector covariables
controles <- "an_bw_s3q5_age + an_bw_polygamous + an_bw_s8q1_childdesired + an_bw_modern_cme"

# Estimamos los modelos
reg_itt1 <- feols(as.formula(paste("Y1_nacimiento ~ D_i +",
                                      controles, "| PROVINCE")),
                    data = datos_completos, vcov = ~ new_csp)

reg_itt2 <- feols(as.formula(paste("Y2_embarazo ~ D_i +",
                                      controles, "| PROVINCE")),
                    data = datos_completos, vcov = ~ new_csp)

reg_itt3 <- feols(as.formula(paste("Y3_uso_anti ~ D_i +",
                                      controles, "| PROVINCE")),
                    data = datos_completos, vcov = ~ new_csp)

reg_itt4 <- feols(as.formula(paste("Y4_cupon ~ D_i +",
                                      controles, "| PROVINCE")),
                    data = datos_completos, vcov = ~ new_csp)

# Calculando medias grupo control para tabla
mean_y1 <- mean(datos_completos$Y1_nacimiento[datos_completos$D_i == 0],
                  na.rm = TRUE)
mean_y2 <- mean(datos_completos$Y2_embarazo[datos_completos$D_i == 0],
                  na.rm = TRUE)
mean_y3 <- mean(datos_completos$Y3_uso_anti[datos_completos$D_i == 0],
                  na.rm = TRUE)
mean_y4 <- mean(datos_completos$Y4_cupon[datos_completos$D_i == 0],
                  na.rm = TRUE)

# Sacando las observaciones de los modelos para tabla
obs_1 <- nobs(reg_itt1)
obs_2 <- nobs(reg_itt2)
obs_3 <- nobs(reg_itt3)
obs_4 <- nobs(reg_itt4)

```

```

# Dando forma a la parte inferior de la tabla
filas_extra <- data.frame(
  term = c("Controles de línea base", "Efectos fijos (Provincia)",
          "Observaciones", "Media del control (10%)"),
  reg1 = c("Sí", "Sí", as.character(obs_1), sprintf("%.3f", mean_y1)),
  reg2 = c("Sí", "Sí", as.character(obs_2), sprintf("%.3f", mean_y2)),
  reg3 = c("Sí", "Sí", as.character(obs_3), sprintf("%.3f", mean_y3)),
  reg4 = c("Sí", "Sí", as.character(obs_4), sprintf("%.3f", mean_y4))
)

# Generando tabla
mapa_coef <- c("D_i" = "Subsidio Completo (100%)")

modelsummary(
  list(
    "(1) Tuvo Nacimiento"      = reg_itt1,
    "(2) Tuvo Embarazo"        = reg_itt2,
    "(3) Usó Anticoncepción"   = reg_itt3,
    "(4) Usó Cupón"            = reg_itt4
  ),
  coef_map = mapa_coef,
  stars = c('*' = .1, '**' = .05, "***" = .01),
  gofomit = ".",
  add_rows = filas_extra,
  title = "Tabla 2. Efectos del tratamiento resultados principales",
  notes = list("Nota: Errores estándar clusterizados
               a nivel de centro de salud entre paréntesis.
               Réplica basada en Panel B (Dupas et al., 2025)."),
  output = "kableExtra"
) %>%
  kable_styling(
    latex_options = c("hold_position", "scale_down", "booktabs"),
    bootstrap_options = "condensed",
    full_width = FALSE
)

```

### 3.6 Punto 6

- Validez de Supuestos:

Table 6: Tabla 2. Efectos del tratamiento resultados principales

	(1) Tuvo Nacimiento	(2) Tuvo Embarazo	(3) Usó Anticoncepción	(4) Usó Cupón
Subsidio Completo (100%)	-0.012 (0.012)	-0.013 (0.013)	0.004 (0.016)	0.044*** (0.011)
Controles de línea base	Sí	Sí	Sí	Sí
Efectos fijos (Provincia)	Sí	Sí	Sí	Sí
Observaciones	6768	6769	6558	6755
Media del control (10%)	0.625	0.703	0.531	0.135

\* p < 0.1, \*\* p < 0.05, \*\*\* p < 0.01

Nota: Errores estándar clusterizados a nivel de centro de salud entre paréntesis. Réplica basada en Panel B (Dupas et al., 2025).

**1. En julio de 2020, el gobierno anunció la gratuidad nacional de la anticoncepción. Explique:(i) de qué manera este anuncio puede violar el supuesto SUTVA, (ii) cuál sería la dirección esperada del sesgo que introduce, y (iii) si considera convincente el argumento de los autores basado en la implementación gradual de la política y en el rezago biológico de nueve meses para observar nacimientos.**

**2. Defina y proporcione ejemplos en el contexto de este estudio de los siguientes efectos: Hawthorne, John Henry, demanda del experimentador (*experimenter demand*) y placebo. ¿En qué dirección sesgaría cada uno de estos efectos los resultados estimados?**

**R/:**

(i). Este anuncio puede violar SUTVA debido a que la oferta del Gobierno pudo afectar la consistencia del tratamiento, pues el anuncio de gratuidad introduce un tratamiento paralelo para el grupo de control.

(ii). En este sentido la dirección esperada del sesgo sería una subestimación del efecto del tratamiento. Si el grupo de control también reduce su fertilidad gracias a la política del gobierno, la diferencia observable entre el grupo de tratamiento y el grupo de control se reduce drásticamente.

(iii). Por otro lado, en el apéndice C los autores argumentan que este evento al ocurrir en Julio de 2020 no tiene efectos en los hallazgos. Este argumento es creíble en tanto, un embarazo dura nueve meses, por lo tanto cualquier reducción en los embarazos de esta política solo hubiera tenido efecto en los resultados desde abril de 2021. Teniendo en cuenta que la recolección final de los datos se dió entre febrero y junio de 2021, esto solo hubiera afectado una fracción pequeña del estudio. Ademas los autores demuestran con el resultado de la tabla A7 que el resultado nulo encontrado se mantiene incluso cuando se excluyen regiones de Cascades y Centre Ouest, donde el gobierno hizo las pruebas piloto de la política en 2019. Por último, el resultado mismo del experimento evita que este posible sesgo sea un problema pues, al encontrar un efecto nulo general, no se observó ningún cambio en la tendencia de natalidad ni en controles ni en tratados. Si este shock hubiera alterado los resultados, la no afectación sería menos creíble.

- **Definiendo y dando ejemplos:**

El efecto Hawthorne ocurre cuando los tratados modifican su conducta porque saben que están siendo observados. En el contexto de este experimento, las mujeres tanto del grupo de tratamiento como del grupo de control podrían prestar mayor atención a su planificación familiar y usar más anticonceptivos solo por recibir la visita de los encuestadores y responder preguntas detalladas sobre sus historiales de embarazo. Lo anterior causaría una subestimación del efecto.

Por otro lado el efecto John Henry aduce a cuando los no tratados cambian su conducta por el hecho de no recibir tratamiento. En este caso un podría suponer que al saber que no recibieron tratamiento las mujeres que recibieron el bono del 10% se esfuerzan para completar su tratamiento poniendo el 90% del costo, de esta manera modificarían sus comportamientos reproductivos causando una subestimación del efecto del programa en los tratados.

El sesgo de demanda del experimentador ocurre cuando los participantes ajustan su comportamiento de acuerdo a lo que consideran que la persona investigadora espera. En este estudio, las mujeres tratadas podrían reportar en las encuestas un mayor deseo de usar anticonceptivos o intenciones de tener menos hijos, simplemente para complacer a los investigadores o encuestadores del proyecto. El sesgo generaría una sobreestimación del efecto del subsidio, haciendo que parezca más exitoso de lo que es.

Por último el efecto placebo ocurre cuando los individuos saben que están haciendo parte de un experimento y solo por eso cambian su comportamiento. En este contexto, el simple hecho de entregar un descuento del 10% a las mujeres del grupo de control podría hacerlas sentir apoyadas institucionalmente o servir como un recordatorio psicológico que las motive a visitar la clínica de salud, uno podría pensar que esto podría causar una subestimación del efecto.

### **3.7 Punto 7**

#### **Robustez del Hallazgo Nulo:**

**El resultado principal es nulo: no hay efecto sobre fecundidad. Los nulos requieren cuidado especial.**

- **Revise su Tabla 2. ¿Aumentó el subsidio el uso de anticoncepción? ¿Y el uso de vouchers? Interprete estos resultados conjuntamente.**
- **¿Son los resultados nulos consistentes? ¿Qué tan robusto es el hallazgo?**

**R/:**

- Como se mencionó anteriormente, al replicar la Tabla 2 del paper, se encontraron resultados consistentes. Tal como concluyen los autores, no hay evidencia de efectos significativos ni en nacimientos de niños vivos, ni en embarazos, ni en el uso de anticonceptivos. Aunque sí hay evidencia de que las mujeres del grupo de tratamiento usaron más los

cupones que las del grupo de control. Lo anterior, como se menciona en el paper es un indicio de que las mujeres que redimieron los cupones ya eran usuarias de los anticonceptivos y probablemente los hubieran comprado aún si solo tenían el cupón del 10%. En ese orden de ideas, el efecto observado se puede dar también porque algunas de las mujeres del grupo control que ya usaban anticonceptivos, los compraban en lugares diferentes a los centros de salud seleccionados, o tenían implantes que no requerían cambios. Al final, no se vio una diferencia en que nuevas usuarias iniciaran a consumir, significativamente, más anticonceptivos por tener acceso gratis.

- En primer lugar, como ya demostramos, la aleatorización estratificada fue correcta, los grupos quedaron balanceados y no hay evidencia de diferencias significativas por resultado de atracción entre el *baseline* y el *endline* entre grupos. En ese sentido, en un primer lugar, los resultados son confiables y el diseño del experimento es robusto. Ahora, los autores presentan estimaciones adicionales analizando grupos en los que posiblemente la intervención debió haber tenido efectos significativos, controlando por las intervenciones adicionales (debates en las aldeas e información entregada individualmente), y por los sesgos preexistentes de las participantes. En términos generales, los autores concluyen que los resultados de las estimaciones en las subpoblaciones del experimento no difieren significativamente de los resultados presentados en la Tabla 2.

Únicamente, en la Tabla 6, se observa un efecto significativo en los nacimientos de niños vivos a un nivel de significancia del 90%, resultado sobre el cual comentan que si bien se podría interpretar que en ausencia de intervenciones a la demanda, se hubieran visto resultados significativos en la disminución de nacimientos, no obstante, como las intervenciones en sí no resultaron estadísticamente significativas y el efecto de todas maneras es moderado, se toman los resultados de la Tabla 2 debido a su mayor poder estadístico.

Finalmente, los autores concluyen que las tasas de fertilidad se determinan principalmente por factores económicos arraigados, los cuales pueden determinar un mayor deseo por parte de las familias de tener más hijos para el cuidado de los padres o para trabajar las tierras de la familia. Este efecto se ve reflejado en las diferentes estimaciones tanto para la muestra completa, como para las submuestras, incluyendo aquellas que analizaban a las mujeres que habían respondido que tenían una necesidad insatisfecha por anticonceptivos o que tenían limitaciones financieras para conseguirlos.

Por todo lo anterior, se puede afirmar que los resultados son suficientemente robustos para hablar de validez interna. Por los argumentos que presentan sobre la selección de la muestra, incluso se podría considerar que los resultados podrían extrapolarse a nivel nacional en Burkina Faso. Sin embargo, aunque se plantea que es un efecto que puede ser extrapolado a nivel internacional y que no es un caso aislado de los países de esa región, consideramos que no hay evidencia suficiente para generalizar la conclusión más allá del país en el que se realizó el experimento.